

《Direct Preference Optimization: Your Language Model is Secretly a Reward Model》是大模型对齐领域非常重要的一篇论文。它的核心贡献是：**把原来复杂、不稳定、成本高的 RLHF/PPO 训练流程，改造成一个更简单的“偏好分类”训练问题**。换句话说，DPO 试图证明：**不一定要显式训练 reward model，也不一定要跑强化学习；只要有“哪个回答更好”的偏好数据，就可以直接训练语言模型更偏向人类喜欢的回答**。

DPO 的核心思想是：语言模型本身就可以被看作一个隐式 reward model；我们可以直接用“好回答 vs 坏回答”的偏好数据训练模型，而不必先训练奖励模型、再用 PPO 做强化学习。

用大白话说：

传统 RLHF 是：

先学一个“打分老师” → 再让模型不断试错，追求高分。

DPO 是：

直接告诉模型：这两个回答里，人类更喜欢 A、不喜欢 B；你以后要更像 A，少像 B。

1. 这篇论文要解决什么问题？

大语言模型经过预训练后，已经学到了大量语言知识、世界知识和推理能力。但问题是：**预训练只是让模型学习“人类文本的分布”，不等于让模型学会“人类真正想要的行为”**。

论文开头举了类似的例子：模型可以知道很多人有误解，但我们并不希望它在回答问题时也按“很多人相信误解”来生成答案；模型可以看到很多低质量代码，但我们希望它写代码时偏向高质量代码。也就是说，关键问题不是“模型知不知道”，而是：**模型在生成时应该选择哪一种行为**。

这就是大模型对齐问题：

预训练模型拥有很多能力，但我们要从这些能力里“筛选出”安全、有用、符合人类偏好的行为。

在 DPO 之前，主流方法是 RLHF，尤其是 PPO-based RLHF。

2. 传统 RLHF 是怎么做的？

论文把传统 RLHF 流程概括为三步：SFT、奖励模型训练、强化学习微调。

2.1 第一步：SFT，监督微调

先拿一些高质量人工回答，让模型模仿。

例如：

用户：请解释什么是 **Transformer**。

人工优质回答：**Transformer** 是一种基于注意力机制的神经网络架构.....

模型通过监督学习学会“像人类专家那样回答”。

这一步得到一个模型，通常叫：

π_{SFT}

它可以理解成一个初步对齐过的参考模型。

2.2 第二步：训练 Reward Model

然后让模型针对同一个问题生成两个回答：

Prompt：请解释什么是 **DPO**。

回答 **A**：清楚、准确、有结构。

回答 **B**：含糊、啰嗦、有错误。

人工标注者选择更好的那个：

A > B

然后训练一个 reward model，让它学会：

$\text{reward}(\text{A}) > \text{reward}(\text{B})$

也就是说，reward model 是一个“打分器”。

2.3 第三步：用 PPO 做强化学习

有了 reward model 后，再用强化学习训练语言模型：

让模型生成回答 → reward model 打分 → PPO 更新模型参数

但这里有一个重要约束：不能让模型为了追求 reward 分数而偏离原模型太远。

所以 RLHF 的目标大致是：

最大化 reward，同时限制新模型和参考模型之间的 KL divergence。

也就是：

既要让回答更符合人类偏好，
又不能让模型为了刷分而“跑偏”。

论文指出，这个流程虽然有效，但有几个明显问题：

1. 要训练多个模型，包括 SFT 模型、reward model、policy model。
2. PPO 训练复杂、不稳定，超参数敏感。
3. 训练过程中需要不断采样模型输出，计算成本高。
4. reward model 可能被过度优化，导致模型学会“钻奖励模型空子”。

3. DPO 的核心洞察是什么？

DPO 的核心洞察是：

在 KL 约束下，给定一个 reward function，其对应的最优 policy 可以写成一个解析形式。
反过来，我们也可以把 reward function 用 policy 表达出来。

这句话比较抽象，通俗解释是：

传统 RLHF 认为：

先学 reward，再根据 reward 找最优模型。

DPO 说：

既然 reward 和最优模型之间存在数学对应关系，
那我能不能不显式训练 reward，
而是直接训练那个最优模型？

答案是：可以。

论文的关键推导是，从 KL-constrained reward maximization 出发，最优策略可以写成：

$$\pi_r(y | x) = \frac{1}{Z(x)} \pi_{ref}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right)$$

这里：

- π_{ref} 是参考模型，通常是 SFT 模型；
- $r(x, y)$ 是某个回答的 reward；
- β 控制模型可以偏离参考模型多少；
- $Z(x)$ 是归一化项，保证概率和为 1。

然后论文把这个公式变形，得到：

$$r(x, y) = \beta \log \frac{\pi_r(y|x)}{\pi_{ref}(y|x)} + \beta \log Z(x)$$

这个公式非常关键。

它说明：一个回答的 reward，其实可以由“当前模型给这个回答的概率”相对于“参考模型给这个回答的概率”的提升程度来表示。

大白话：

如果 DPO 训练后的模型，比参考模型更倾向于生成某个回答，那么 DPO 会把这种“概率提升”解释成：这个回答更符合偏好，因此隐式 reward 更高。

如果 DPO 训练后的模型，比参考模型更不倾向于生成某个回答，那么它就被解释成不符合偏好，因此隐式 reward 更低。

这就是论文标题里的那句话：

Your Language Model is Secretly a Reward Model

你的语言模型其实暗中就是一个奖励模型。

4. DPO 如何从“偏好数据”直接训练模型？

偏好数据通常长这样：

x: 用户问题
y_w: 人类更喜欢的回答, winner
y_l: 人类不喜欢的回答, loser

传统 reward model 会学习：

$r(x, y_w) > r(x, y_l)$

DPO 则把 reward 替换成语言模型概率比：

当前模型相对于参考模型，
应该更提高 y_w 的概率，
更降低 y_l 的概率。

DPO 的目标函数是：

$$\mathcal{L}_{DPO}(\pi_{\theta}; \pi_{ref}) = -\mathbb{E}_{(x, y_w, y_l) \sim D} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{ref}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{ref}(y_l|x)} \right) \right]$$

不用被公式吓到。它本质上就是一个二分类损失：

给定两个回答 y_w 和 y_l ，
模型应该判断 y_w 比 y_l 更好。

只不过它不是简单地让模型提高 y_w 的概率、降低 y_l 的概率，而是看：

当前模型相对于参考模型，对 y_w 提高了多少；
当前模型相对于参考模型，对 y_l 提高了多少。

然后要求：

y_w 的相对提升 > y_l 的相对提升

这就保留了 RLHF 里的 KL 约束思想：**不要让模型无限偏离原始参考模型。**

5. 为什么 DPO 比“直接学 winner”更好？

一个很容易想到的简单方法是：

只用人类喜欢的回答 y_w 做监督微调。

这就是论文里提到的 Preferred-FT。

但这种方法有两个问题。

第一，它只告诉模型“什么是好的”，没有充分利用“什么是不好的”。

例如：

- A: 准确、简洁、结构清晰。
- B: 啰嗦、错误、跑题。

Preferred-FT 只学 A，不明确打压 B。

DPO 则同时做两件事：

- 提高 A 的相对概率；
- 降低 B 的相对概率。

第二，简单提高 winner 概率可能导致模型过拟合偏好数据，或者让模型分布偏移太大。

DPO 通过和 reference model 比较，等于隐含保留了一个“别跑太远”的约束。

通俗说：

Preferred-FT 像是只告诉学生“背这个标准答案”。
DPO 则是告诉学生：“这个答案为什么比那个答案更好，以后你要更偏向这种回答风格，同时不要完全脱离你原来的语言能力。”

6. DPO 和 PPO-RLHF 的区别

可以用一张逻辑表理解：

维度	PPO-based RLHF	DPO
是否训练 reward model	需要	不需要显式 reward model
是否使用强化学习	需要 PPO	不需要
训练复杂度	高	低
稳定性	容易不稳定	更稳定
是否需要在线采样	需要	不需要训练中反复采样
输入数据	偏好对	偏好对
核心目标	最大化 reward，约束 KL	直接优化偏好概率，隐式约束 KL
实现难度	高	接近普通 supervised learning

论文强调，DPO 实际上优化的是与传统 RLHF 类似的目标：**最大化 reward，同时不要离 reference policy 太远**。但它通过数学变换，把这个目标变成了一个简单的 binary cross entropy classification loss。

7. β 参数怎么理解？

DPO 里有一个重要超参数：

β

它控制模型相对于 reference model 的偏移程度。

可以粗略理解为：

β 越大，模型越保守，越不容易偏离 reference model；
 β 越小，模型越激进，更强烈地追求人类偏好。

但这个解释要稍微谨慎，因为具体效果还和实现、数据、模型大小有关。

通俗类比：

reference model 像原来的驾驶路线。

偏好数据告诉你哪条路线更好。

β 控制你改路线的力度：

β 大：小幅调整，稳一点；

β 小：大幅调整，冲一点。

8. DPO 的训练流程

论文给出的 DPO 流程非常直接：

第一步：准备偏好数据

每条数据包括：

```
prompt x
preferred response y_w
dispreferred response y_l
```

例如：

x: 请解释什么是 attention。
y_w: 结构清楚、解释准确。

y_l: 含糊、错误、没有重点。

第二步：准备 reference model

通常 reference model 就是 SFT 模型。

如果没有现成的 SFT 模型，可以先用 preferred completions 做一次监督微调，得到一个 reference model。

第三步：用 DPO loss 训练当前模型

训练目标是：

让当前模型相对于 reference model，
更偏向 y_w，
更远离 y_l。

注意：训练过程中不需要像 PPO 那样不断采样、打分、更新。

这也是 DPO 工程上非常有吸引力的地方。

9. 论文实验做了什么？

论文主要在三个任务上验证 DPO：

9.1 情感控制生成

任务：给定 IMDb 电影评论前缀，让模型继续生成更积极的文本。

这个任务有一个好处：可以用情感分类器作为近似 ground-truth reward，因此方便比较 reward/KL tradeoff。

论文发现：

在 reward 和 KL 的权衡上，DPO 的 frontier 明显优于 PPO；甚至 PPO 拿到 ground-truth reward 时，DPO 仍然表现更好。

通俗解释：

DPO 能用更小的“偏离原模型代价”，换来更高的偏好收益。

也就是：

改得更准，而不是改得更猛。

9.2 Reddit TL;DR 摘要

任务：给 Reddit 帖子生成摘要。

评估方式：用 GPT-4 判断模型生成摘要和参考摘要哪个更好，并计算 win rate。

论文结果显示：

DPO 的 win rate 约 61%，
PPO 最优约 57%，
DPO 更高且对采样温度更鲁棒。

论文还提到，DPO 在 TL;DR 摘要任务上超过 PPO 的最佳表现，并且比 PPO 对 sampling temperature 更稳定。

大白话：

PPO 的效果更容易受到采样温度影响，温度一变，质量可能掉得明显；DPO 更稳。

9.3 Anthropic-HH 单轮对话

任务：给用户问题生成有帮助、无害的回答。

论文比较了 DPO、Best-of-128、Preferred-FT、Pythia-2.8B 等方法。

结果显示：

DPO 是唯一一个在 Anthropic-HH 测试集上超过 chosen responses 的计算高效方法，并且与 Best-of-128 这种成本很高的方法相当或更好。

Best-of-128 是什么意思？

生成 128 个候选回答，
再用 reward model 选最好的。

这种方法效果可能不错，但推理成本非常高。DPO 的优势是：

训练后直接生成即可，
不用每次生成 128 个答案再筛选。

10. 论文还验证了 GPT-4 作为评估器是否可靠

因为摘要和对话质量很难用 ROUGE 这类传统指标衡量，所以论文用 GPT-4 做自动评估。

但作者也意识到：GPT-4 评估可能有偏差。

因此他们做了 human study，对比 GPT-4 判断和人类判断。结果发现：

GPT-4 和人类判断的一致性，大致接近或高于人类标注者之间的一致性。

这说明，在这些实验里，用 GPT-4 作为评估代理是相对合理的。

不过论文也承认，GPT-4 的判断会受 prompt 影响，这也是未来需要继续研究的问题。

11. DPO 的理论贡献：为什么它不是“拍脑袋简化”？

DPO 不是简单地说：

PPO 太麻烦了，我们换个简单 loss 吧。

它的理论贡献在于：

1. 从 KL-constrained RLHF objective 出发；
2. 推导出 reward function 和 optimal policy 的对应关系；
3. 用 **Bradley-Terry preference model** 表达偏好概率；
4. 发现 partition function 在偏好差值中会抵消；
5. 因此可以直接把 reward loss 改写成 policy loss。

这里面最关键的是 Bradley-Terry 模型。

Bradley-Terry 模型认为，人类偏好一个回答胜过另一个回答的概率，取决于两个回答 reward 的差值：

回答 A 比回答 B 更受偏好的概率
$$= \text{sigmoid}(\text{reward}(A) - \text{reward}(B))$$

DPO 利用了这一点。

因为偏好只看 reward 差值，而 reward 里的 $\beta \log Z(x)$ 对同一个 prompt 下两个回答是一样的，所以会相互抵消。

通俗说：

我们不需要知道每个回答的绝对分数。
我们只需要知道两个回答谁更好。
只要比较的是差值，很多复杂的归一化项就可以消掉。

这就是 DPO 能够避开显式 reward model 和 RL 训练循环的关键。

12. “语言模型就是隐式奖励模型”到底是什么意思？

论文标题很有意思：

Your Language Model is Secretly a Reward Model

这句话不是说语言模型真的内部有一个单独的 reward head，而是说：

当前模型 π_θ 和参考模型 π_{ref} 的概率比，
可以被解释成一个隐式 reward。

也就是：

$$r_{\text{hat}}(x, y) = \beta \log [\pi_\theta(y|x) / \pi_{\text{ref}}(y|x)]$$

如果当前模型比参考模型更倾向于生成某个回答：

$$\pi_\theta(y|x) > \pi_{\text{ref}}(y|x)$$

那么这个回答的隐式 reward 更高。

如果当前模型比参考模型更不倾向于生成某个回答：

$$\pi_\theta(y|x) < \pi_{\text{ref}}(y|x)$$

那么这个回答的隐式 reward 更低。

所以 DPO 不需要额外训练一个 reward model，因为：

当前 policy 本身相对于 reference policy 的变化，就可以解释为 reward。

这也是 DPO 最漂亮的地方。

13. DPO 的梯度直觉

论文还分析了 DPO loss 的梯度。

结论很直观：

如果模型错误地更偏好 **loser**，
那这条样本的更新权重会更大；
如果模型已经正确偏好 **winner**，
那更新权重会变小。

也就是说，DPO 不是机械地对所有样本一视同仁，而是会重点纠正当前模型判断错的样本。

通俗类比：

老师不会对已经做对的题反复讲很多遍；
老师会重点讲你最容易混淆、最容易做错的题。

这比简单的 “increase winner / decrease loser” 更稳。

论文也提到，如果去掉这种动态权重，使用 naive probability ratio objective，可能会导致模型退化。

14. DPO 为什么重要？

这篇论文之所以成为经典，主要因为它降低了偏好对齐训练的门槛。

在 DPO 之前，如果你想做类似 RLHF 的训练，通常需要：

SFT model
reward model
PPO trainer
KL penalty
rollout sampling
value model / critic
大量超参数调节
较高工程复杂度

DPO 之后，流程变成：

reference model
preference pairs

DPO loss

普通 supervised fine-tuning 风格训练

这对开源社区和中小团队非常重要。

因为 PPO-based RLHF 不仅难，而且容易训练崩；DPO 则更像一个稳定的监督学习任务，工程实现门槛低很多。

15. DPO 的局限性

论文自己也提到了一些局限和未来方向。

15.1 分布外泛化仍需更多研究

DPO 在论文中的分布外测试上表现不错，比如从 Reddit TL;DR 摘要迁移到 CNN/DailyMail 新闻摘要，DPO 仍然优于 PPO。

但作者也承认，这只是初步证据。

真正的问题是：

DPO 在更大模型、更复杂任务、更长上下文、多轮对话中，是否仍然稳定优于 PPO？

还需要更多实验。

15.2 可能仍然存在 reward over-optimization

虽然 DPO 没有显式 reward model，但它依然在优化偏好数据。

如果偏好数据本身有偏差，或者模型过度拟合偏好对，仍然可能出现过优化问题。

例如：

模型学会了某种“看起来像好回答”的套路，但真实质量未必提升。

15.3 实验规模有限

论文实验最大到约 6B 参数模型。

对于更大规模的 state-of-the-art LLM，DPO 的效果还需要继续验证。

当然，后续大模型生态中 DPO 及其变体已经被广泛使用，但就这篇论文本身而言，它的实验规模仍有限。

15.4 自动评估有局限

论文使用 GPT-4 作为评估器，并做了 human validation。

但作者也承认，GPT-4 判断会受到 prompt 影响。

这说明：

LLM-as-a-judge 可以用，
但不能完全无脑相信。

16. 用一个简单例子理解 DPO

假设 prompt 是：

请解释什么是 `Transformer`。

有两个回答：

A: `Transformer` 是一种基于自注意力机制的神经网络架构.....
B: `Transformer` 是一种数据库查询语言.....

人类偏好：

A > B

传统 RLHF：

1. 训练 `reward model`，让 `reward(A) > reward(B)`
2. 用 PPO 训练语言模型，让它生成高 `reward` 回答

DPO：

- 直接训练语言模型，让它相对于 `reference model`：
- 更愿意生成 A
 - 更不愿意生成 B

但它不是简单粗暴地把 A 概率拉高，而是看：

$$\frac{\pi_{\theta}(A)}{\pi_{\theta}(B)} / \frac{\pi_{\text{ref}}(A)}{\pi_{\text{ref}}(B)}$$

目标是：

$$\frac{\pi_{\theta}(A)}{\pi_{\theta}(B)} \text{ 相对 } \frac{\pi_{\text{ref}}(A)}{\pi_{\text{ref}}(B)} \text{ 的提升} > 1$$

这样既能学偏好，又能避免模型远离原来的语言分布太多。

17. DPO 和 InstructGPT/RLHF 的关系

如果把 InstructGPT/RLHF 看作经典三阶段范式：

Pretraining → SFT → Reward Model → PPO

那么 DPO 可以理解为对后两步的简化：

Pretraining → SFT → DPO

它不是否定 RLHF 的目标，而是说：

RLHF 里的偏好优化目标，可以不通过 PPO 来实现。
我们可以直接把它转成一个 preference classification objective。

所以 DPO 更像是：

RLHF 目标的监督学习化实现。

这也是它在大模型训练工程里非常有价值的原因。

18. 这篇论文的核心贡献总结

可以概括为四点：

1. 提出 DPO

一种不需要显式 reward model、不需要强化学习的偏好优化方法。

2. 给出理论推导

证明在 KL 约束的 RLHF 框架下，reward 和 optimal policy 之间存在可利用的解析关系。

3. 把 RLHF 训练转成分类损失

把复杂的 PPO 优化，转化为一个基于 preference pairs 的 binary cross entropy loss。

4. 实验证明有效

在情感控制、摘要、单轮对话任务上，DPO 达到或超过 PPO-based RLHF，且训练更简单、更稳定、成本更低。

19. 最后用一句大白话收束

RLHF/PPO 像是：先训练一个裁判，再让模型反复比赛、根据裁判打分调整。

DPO 像是：直接拿“人类更喜欢哪个回答”的判例训练模型，让模型自己内化这个偏好标准。

它最重要的价值不是说“DPO 永远比 PPO 好”，而是提出了一个非常强的工程与理论观点：

大模型偏好对齐不一定非要走复杂强化学习路径；

在合适的数学重参数化下，偏好学习可以直接变成稳定、简单、可扩展的监督式训练。