

大模型不是“凭空聪明”的，它的能力、偏差、风险和边界，很大程度上都来自训练数据；因此，数据从哪里来、怎么筛、筛掉了什么、有没有被污染、如何记录和治理，都非常关键。

1. 为什么 Data 是大模型的起点？

前面几讲讨论的是大模型的能力和危害；这一讲开始往里看：**大模型到底是怎么被造出来的？**

机器学习的起点是训练数据。对大语言模型来说，训练数据通常不是人工精心标注的问答对，而是大量“原始文本”：网页、书籍、新闻、代码、论文、论坛、百科等。讲义强调，模型要拥有语言能力和世界知识，就需要覆盖足够广的领域、文体、语言和场景。

通俗说：

大模型像一个读了很多书、网页、论坛帖子的人。它知道什么、说话像谁、偏见来自哪里，很大程度上取决于它“读过什么”。

2. Web 是大模型训练数据的重要来源，但不是完美来源

讲义重点讨论了网页数据，因为网页非常大，而且容易获取。比如 Common Crawl 会定期爬取互联网并公开快照，因此很多模型都会用它作为数据来源，包括 T5、GPT-3、Gopher 等。讲义提到 Common Crawl 的某个快照有 320TB 数据，但这仍然远小于 Google 搜索索引规模。

但是，网页数据有几个天然问题：

第一，**网页不是全人类的均匀代表**。互联网用户本身就存在结构性偏差，比如更偏年轻人、发达国家用户、男性用户等。讲义举例，GPT-2 使用的 WebText 数据与 Reddit 有关，而 Reddit 用户结构并不代表全社会。

第二，**网页上有大量低质量内容**。包括垃圾文本、模板页、广告、自动生成文本、OCR 错误、机器翻译错误等。

第三，**网页数据包含偏见和伤害性内容**。例如针对某些身份群体的负面表达、毒性语言、歧视性共现等。

通俗说：

Web 数据像一座巨大的垃圾场兼图书馆：里面既有百科全书、论文和高质量文章，也有广告、谣言、骂战、复制粘贴、机器生成垃圾。直接全吃进去，模型不一定更聪明，反而可能更脏、更偏、更浪费算力。

3. WebText / OpenWebText：用 Reddit 链接筛出“高质量网页”

GPT-2 的训练数据 WebText 不是直接抓全网，而是利用 Reddit 做过滤：收集 Reddit 上获得至少 3 个 karma 的外链，认为这些链接更可能是人类觉得有价值的内容。最终 WebText 大约有 40GB 文本。OpenAI 没有公开 WebText，后来社区做了一个类似版本叫 OpenWebText，大约 38GB。

这背后的思想是：

不直接相信全网，而是用 Reddit 用户的投票行为作为“质量信号”。

但这也带来问题：Reddit 本身的人群结构、兴趣偏好、政治倾向、语言环境都会进入数据集。RealToxicityPrompts 相关研究发现，OpenWebText 和 WebText 中都有一定比例的高毒性文本，且部分内容来自被封禁或隔离的 subreddit。

通俗说：

Reddit 点赞可以帮你过滤掉一部分垃圾，但它不是“客观真理”。它只是某一类互联网用户的偏好投票，所以筛出来的数据也带着这个群体的影子。

4. C4：大规模清洗 Common Crawl，但“清洗”本身也会制造偏差

C4，全称 Colossal Clean Crawled Corpus，是 T5 模型使用的大型语料。它从 Common Crawl 出发，做了很多清洗，例如去掉“bad words”、去掉代码、过滤非英文文本等，最后得到 806GB 文本、约 1560 亿 token。

但讲义重点不是说 C4 很大，而是说：**清洗规则本身会影响数据结构。**

例如，过滤“坏词”看似合理，但可能把一些非攻击性的身份表达也误删掉。讲义提到，涉及性取向的词更容易被过滤掉；某些方言，比如 African American English，也更容易被过滤。

通俗说：

数据清洗不是简单的“把脏东西洗掉”。你用什么规则洗，就会决定哪些声音留下、哪些声音消失。

如果规则很粗糙，就可能把弱势群体的正常表达也当成“脏东西”删掉。

这对大模型很重要，因为模型不是只学习保留下来的内容，也会因为某些内容被删掉而形成“缺失的世界观”。

5. Benchmark contamination：测试题可能已经出现在训练数据里

讲义还强调了一个大模型评估中特别重要的问题：**数据污染，也就是 benchmark contamination。**

传统机器学习里，训练集和测试集通常可以比较清楚地分开。但大模型的训练数据来自互联网，而很多测试集、论文数据、问答样例也可能出现在互联网里。于是，模型在评测时可能不是“真正会做题”，而是“之前见过题”。

讲义区分了两类污染：

1. **Input-and-output contamination**：输入和标准答案都出现在训练数据里。
2. **Input contamination**：输入出现过，但答案不一定出现过。

通俗说：

这就像考试前学生刷到了原题。分数高不一定说明他理解了知识，也可能只是记住了答案。对大模型来说，如果 benchmark 出现在训练语料中，模型能力就会被高估。

这也是为什么现在很多模型评测越来越强调去污染、构造新题、隐藏测试集、动态评测。

6. GPT-3 数据集：不是只靠 Common Crawl，而是混合多种来源

GPT-3 的训练数据包括经过筛选的 Common Crawl、WebText2、Books1、Books2、Wikipedia 等。讲义提到，GPT-3 对 Common Crawl 做了筛选：用一个分类器判断 Common Crawl 文档是否像 WebText，然后更倾向保留类似 WebText 的内容。

同时，虽然 Common Crawl 在原始数据中占比很高，但训练时会被降采样。也就是说，GPT-3 并不是简单地“网页越多越好”，而是会调整不同数据源在训练中的权重。

通俗说：

GPT-3 的数据配方有点像做菜：网页是主料，但不能全放网页，还要加书籍、百科等；而且不同材料放多少，会影响模型最后的味道。

7. The Pile：高质量非网页数据越来越重要

讲义接着介绍 The Pile，这是 EleutherAI 发布的一个 825GB 英文数据集，由 22 个相对高质量的数据源组成，包括 PubMed、arXiv、GitHub、Stack Exchange、法律文本、书籍、Wikipedia 等。

The Pile 的核心思想是：

不只是从大而杂的网页中筛，而是主动收集更专业、更高质量、更多样的数据源。

讲义中的图表显示，The Pile 包含大量 GPT-3 数据覆盖不足的信息，比如数学、论文、邮件、医学、法律、代码等。结论是：The Pile 说明高质量非网页数据是很有价值的补充。

通俗说：

如果只靠互联网网页，模型可能像一个刷论坛、看新闻、逛百科很多的人；
加入 The Pile 这类数据后，它会更像一个还读过论文、代码库、医学文献、法律文本、问答社区的人。

8. 数据文档：不能只发布数据，还要说明数据是怎么来的

讲义第二部分讲的是 **Documentation of datasets**，也就是数据集文档化。

它提到几个重要框架：

- **Datasheets for Datasets**：像电子元件有 datasheet 一样，数据集也应该有说明书。
- **Data Statements**：更专门面向 NLP 数据集，记录语言、说话人、标注者、语域、收集目的等信息。
- **Model Cards**：模型层面的报告卡，说明模型用途、限制和风险。

数据文档需要回答的问题包括：数据为什么创建？谁创建？谁资助？数据实例代表什么？是否包含隐私？怎么收集？谁参与标注？是否做过伦理审查？怎么清洗？能用于什么任务？不应该用于什么任务？如何维护和更新？

通俗说：

数据集不能只是一个压缩包。
它应该像食品包装一样有“营养成分表”，告诉你里面有什么、怎么做出来的、适合什么用途、有什么风险。

这对大模型尤其关键，因为训练数据一旦进入模型，后续很难完全追踪、删除或纠正。

9. Data ecosystem：数据不是静态文件，而是一个生态系统

最后一部分从更宏观的角度讨论数据生态。

讲义指出，在机器学习研究中，人们常把数据集看成一个固定对象：收集好、清洗好、丢给模型训练。但在真实产业中，数据其实处在一个复杂生态里，涉及生产、治理、质量、安全、权限、收益分配和责任。

这里提到几个概念：

第一， **Data governance 数据治理** 。组织需要管理数据的创建、质量、安全和使用边界。

第二， **BigScience 数据治理工作组** 。它试图以更负责任的方式收集多语言数据，而不是无差别地抓取网页。

第三， **Data dignity 数据尊严** 。这个概念强调：数据是人创造的，而且很多数据不是纯个人的，而是群体关系的产物，比如邮件、社交互动、基因数据。数据单独看价值不大，但聚合起来价值巨大。

通俗说：

大模型公司不是凭空获得价值，它们从大量人的文字、行为、知识和创作中获得训练材料。因此，数据不只是技术问题，也是权利、劳动、分配和治理问题。

讲义还提到一种观点：应该把数据理解成一种劳动，而不只是财产权；未来可能需要数据联盟这样的组织，代表数据生产者与数据购买者进行集体谈判。

10. 这讲的核心结论

这份讲义最后的总结非常清晰：

1. 世界上的文本数据极其巨大，包括公开网页和公司私有数据。
2. 不能简单训练“所有数据”，因为这既浪费算力，也会引入大量低质量和有害内容。
3. 过滤和清洗是必要的，但过滤规则会带来新的偏差。
4. 高质量、非网页的数据源很有价值，The Pile 是一个代表。
5. 必须认真记录、检查和治理训练数据，否则模型能力、偏见和风险都很难解释。

一句话理解这讲

大模型的数据问题，不是“数据越多越好”，而是“什么数据、谁的数据、怎么筛选、筛掉了谁、有没有污染、有没有说明书、谁从中获益”。

换成更通俗的比喻：

训练大模型就像培养一个人。

它读什么书、看什么网页、听谁讲话、接触什么圈层，会决定它懂什么、偏向什么、忽略什么、误解什么。

所以，大模型的 Data 不是底层杂活，而是决定模型能力和社会影响的第一层地基。