

一、核心概念：什么是语言模型？

- **讲义要点：**传统的 n -gram 模型和现代的大语言模型（LLM）核心任务是相似的——为词语序列分配概率，并 **通过预测下一个最可能出现的词来生成文本**。它们在海量文本上进行训练，在猜测下一个词的过程中，模型自然而然地学习到了丰富的语言知识。
- **通俗解释（手机输入法）：**大语言模型本质上就是一个 **超级无敌进化版的“手机输入法联想功能”**。你在微信聊天框打出“今天天气”，输入法可能会自动联想到“很好”或“真糟糕”。LLM 做的也是完全一样的事，只不过它读完了整个人类互联网的文本，所以不仅能联想到下一个词，还能一路联想下去，变成写文章、写代码或聊天。

二、三大主流模型架构

讲义中提到了基于 Transformer 的三种大模型技术路线：

1. 纯解码器（Decoder-only）

- **代表模型：**GPT 系列、Claude、Llama、Mixtral。
- **特点：**从左到右单向预测文本。
- **通俗解释（接话茬高手）：**它就像一个只管往前接话的人，你给它开个头，它就根据前面的话，不断地往后一个字一个字地接下去。目前市面上最火的聊天机器人大多属于这一类。

2. 纯编码器（Encoder-only）

- **代表模型：**BERT 系列。
- **特点：**利用上下文（左边和右边的词）来预测被盖住的词，通常用于分类任务。
- **通俗解释（完形填空大师）：**它不擅长从无到有地写长文章，但非常擅长做“完形填空”。你给它一段话，把中间挖掉一个词，它能结合前后的意思准确把这个词猜出来。适合用来做判断文章感情（好评/差评）等任务。

3. 编码器-解码器（Encoder-Decoder）

- **代表模型：**Flan-T5、Whisper。
- **特点：**将一个输入序列映射到另一个输出序列，常用于翻译和语音识别。
- **通俗解释（同声传译员）：**编码器负责“听懂”输入的内容（比如一句英文），把意思打包好；解码器负责把这个打包好的意思“翻译”输出出来（比如一句中文）。

三、文本生成时的采样策略（如何挑选下一个词）

当大模型计算出下一个词的概率后，如何把这个词真正“写”出来？讲义介绍了不同的“解码（Decoding）”策略：

1. 贪婪解码（Greedy Decoding）

- **原理：**永远只挑概率最高的那一个词。

- **通俗解释（死板的学霸）**：模型每一步都选最安全、绝对最正确的词。这导致它说出来的话非常死板、机械，而且 **极度容易卡在车轱辘话里不断重复**。

2. 随机采样的问题

- **原理**：按概率随机扔骰子选词。
 - **通俗解释**：虽然概率高的词最容易被选到，但因为词表里有太多稀奇古怪的低概率词（长尾词），一旦字数变多，模型就一定会抽中一两个奇怪的词，导致 **整句话突然变得语无伦次**。

为了平衡 **生成质量（准确度）** 与 **多样性（创意）**，通常会使用以下改良策略：

- **Top-k 采样**：
 - **方法**：不管三七二十一，永远只在概率最高的前 k 个词里挑选，把剩下的淘汰掉。
 - **比喻**：皇上选妃，无论这次报名的佳丽整体质量如何，永远只在最漂亮的前10名里抽。
- **Top-p 采样（核采样，Nucleus Sampling）**：
 - **方法**：动态挑选词群，直到这些词的累积概率达到了 p （例如 90%），然后在这个集合里挑。
 - **比喻**：这次不是固定人数了。如果大家都挺优秀，就多选几个人进入候选池；如果只有一两个人特别拔尖（概率很大），那候选池就只留这一两个人。这样比 Top-k 更灵活、更不容易出错。
- **温度采样（Temperature Sampling）**：
 - **方法**：通过调整物理学中的“温度”参数 τ 来改变概率分布的形状。
 - **通俗解释（灵感调节器）**：
 - **低温度（ τ 趋近于 0）**：模型变得非常保守、清醒。它会把高概率的词变得概率更高，低概率的词压得更低，说话更像“贪婪解码”，稳重但无趣。
 - **高温（ $\tau > 1$ ）**：模型喝醉了或者“灵感大爆发”。原本概率很低的词，概率被放大了，模型会变得非常有创意、天马行空，但也更容易胡言乱语。

四、预训练算法（大模型是怎么练成的？）

- **讲义要点**：采用 **自监督学习（Self-supervised training）**。不需要人工打标签，文字本身就是标签（用前 t 个词预测第 $t+1$ 个词）。使用交叉熵损失函数（Cross-entropy loss）来拉近模型预测与真实课文之间的差距。
- **重要机制：导师强迫（Teacher Forcing）**：
 - **讲义要点**：在训练过程中，不管模型上一步猜对了还是猜错了，在下一步预测时，我们都 **必须喂给它课本上的正确历史文本**，而不是让它基于自己猜错的话继续瞎猜。
 - **通俗解释（严厉的私塾老师）**：大模型背书时，背出了“床前明月光，疑似鞋一双”。这时候，如果是真人在聊天（生成阶段），它会顺着“鞋一双”继续往下编“两双摆中央”；但是在 **预训练（读书上学）阶段**，老师（Teacher Forcing）会一戒尺打过去，强行把书本翻到正确的一页，命令它：“不对！擦掉，正确的词是‘地霜’，

现在你给我根据‘床前明月光，疑似地上霜’，去猜下一句是什么！”这种机制能让模型在训练时高效地学习正确的语言规律，而不至于一步错、步步错。

总结

这份讲义的核心思想可以总结为一句话：大语言模型是一个通过“导师盯着读完人类所有书（预训练与导师强迫）”的超级智能输入法，它通过各种精妙的技术架构（如纯解码器架构）和概率调节阀门（Top-p、温度等），实现了像人类一样流畅、有创意且在大部分时候符合逻辑的文本输出。