

这讲主要回答一个问题：**GPT-3 这样的语言模型到底“会什么”？它的能力边界在哪里？**

GPT-3 不是为具体任务专门训练出来的模型，它只是学会了“预测下一个词”，但通过提示词和少量示例，它居然可以在问答、翻译、常识推理、算术、写新闻、语法纠错等很多任务上表现出一定能力；不过它的表现很不稳定，有些任务接近甚至超过专门模型，有些任务仍明显落后。

1. 这讲的核心主线：语言模型如何变成任务模型？

CS324 首先强调：GPT-3 本质上是一个 **language model**，也就是给一串 token 分配概率，并预测下一个 token。

通俗地说，它原本只是在做一件事：

给它前半句话，它猜后半句话。

比如：

```
the mouse ate → the cheese
```

但很多 NLP 任务都可以被包装成“补全文本”的形式。

比如问答任务：

```
Q: What school did Burne Hogarth establish?  
A:
```

模型只要把后面补成：

```
School of Visual Arts
```

它就完成了问答任务。

所以这讲的关键概念是 **adaptation**，适配：

也就是把一个通用语言模型，变成能完成具体任务的模型。

2. 两种适配方式：训练 vs 提示词

讲义里把适配分成两类：

2.1 Training：重新训练或微调

包括：

- 1. 用语言模型做特征，再训练一个新模型；
- 2. 直接 fine-tune 原模型；
- 3. 用 lightweight fine-tuning 等折中方法。

但 GPT-3 有 175B 参数，如果只用几个样本去微调，很容易过拟合。

通俗理解：

你让一个超级复杂的大脑，只根据 5 道题重新改变自己的神经连接，它很可能不是“学会规律”，而是“死记这 5 道题”。

所以这讲暂时不重点讲 fine-tuning，而是重点看 prompting。

2.2 Prompting / In-context learning：通过提示词让模型临时学会任务

Prompting 分三种：

类型	含义	通俗解释
Zero-shot	不给例子	直接问模型
One-shot	给 1 个例子	给它看一题，再让它做下一题
Few-shot	给几个例子	给它几道样题，让它模仿格式和规律

这就是 GPT-3 论文里最有代表性的发现：
模型参数越大，prompt 里示例越多，表现通常越好。

3. GPT-3 在哪些任务上被测试？

这讲按任务类型总结了 GPT-3 的能力，主要包括：

- 1. Language modeling，语言建模；
- 2. Question answering，问答；
- 3. Translation，翻译；
- 4. Arithmetic，算术；

5. News article generation, 新闻生成;

6. Novel tasks, 新奇任务。

下面逐类解释。

4. 语言建模：GPT-3 表现非常强

语言建模是 GPT-3 的“本职工作”。

评估指标是 **perplexity**, **困惑度**。

困惑度越低, 说明模型越能准确预测下一个词。

通俗理解:

困惑度就是模型在每一步平均有多“困惑”。

如果困惑度是 20, 大概可以理解为模型平均每次像是在 20 个合理候选里做选择。

困惑度越低, 说明它越知道接下来该出现什么。

在 Penn Tree Bank 数据集上, GPT-3 的 perplexity 是 20.5, 明显优于当时的 BERT-Large-CAs1 的 31.3。

这说明:

如果任务本身就是预测语言, 那么 GPT-3 极其强。

但讲义也提醒了一个重要问题: **train/test leakage**, **训练集和测试集泄漏**。

因为 GPT-3 的训练语料非常大, 很难确认某些测试数据是否已经被它“见过”。所以评价大模型时, 数据污染是一个很大的问题。

5. LAMBADA: 长程依赖能力很强

LAMBADA 的任务是:

给出一段上下文, 让模型预测最后一个词。

这个任务难点在于:

最后一个词往往需要理解很长的前文才能猜对。

通俗例子:

```
Alice was friends with Bob. Alice went to visit her friend ____.
```

答案应该是：

Bob

GPT-3 few-shot 在 LAMBADA 上的 perplexity 是 1.92，而之前 SOTA 是 8.63。

这说明 GPT-3 对长上下文里的语言线索有很强的捕捉能力。

通俗理解：

它不是只看最后几个词，而是能把前面很远的信息拿来用。

6. HellaSwag：常识推理接近 SOTA，但没有超过

HellaSwag 是常识推理任务。

给模型一个场景，让它从多个选项里选最合理的后续。

比如：

Several cake pops are shown on a display. A woman and girl are shown making the cake pops in a kitchen. They ...

选项可能包括：

1. bake them, then frost and decorate.
2. taste them as they place them on plates.
3. put the frosting on the cake as they pan it.
4. come out and begin decorating the cake as well.

GPT-3 的准确率是 79.3，而 SOTA 是 85.6。

这里有一个关键点：

SOTA 是在 HellaSwag 训练集上 fine-tune 过的，而 GPT-3 没有针对这个任务训练，只是 few-shot prompting。

所以虽然它没超过 SOTA，但已经很惊人。

通俗理解：

一个没专门刷过这套题的人，靠平时读了大量书和文章，居然能接近专门刷题训练出来的学生。

7. 问答能力：有些强，有些弱

讲义讨论了 closed-book question answering，也就是闭卷问答。

闭卷问答的意思是：

模型不能查数据库，也不能读取文档，只能靠训练时学到的知识回答。

这和 RAG 不一样。RAG 是可以检索外部资料的。

7.1 TriviaQA

TriviaQA 是 trivia 问答。GPT-3 表现不错：

模型	Accuracy
RAG	68.0
GPT-3 zero-shot	64.3
GPT-3 few-shot	71.2

GPT-3 few-shot 甚至超过了 RAG。

这说明 GPT-3 在一些事实性问答上确实“记住了”很多世界知识。

7.2 WebQuestions

WebQuestions 更接近 Google 搜索式问题。结果是：

模型	Accuracy
RAG	45.5
GPT-3 zero-shot	14.4
GPT-3 few-shot	41.5

few-shot 后 GPT-3 接近 RAG，但 zero-shot 很弱。

7.3 NaturalQuestions

NaturalQuestions 更复杂，答案也更长。结果是：

模型	Accuracy
RAG	44.5

模型	Accuracy
GPT-3 zero-shot	14.6
GPT-3 few-shot	29.9

这里 GPT-3 明显落后于 RAG。

这一部分的核心结论是：

GPT-3 具备一定闭卷知识问答能力，但它不是可靠知识库。越需要具体事实、最新信息、复杂检索，它越不如带检索的系统。

这对你理解今天的 RAG 很关键：

大模型会“生成答案”，但不一定能稳定“找到事实”。

8. 翻译：英译外较弱，外译英很强

讲义以 German → English 为例，GPT-3 few-shot 的 BLEU 达到 40.6，而监督式 SOTA 是 40.2。

也就是说，在德译英任务上，GPT-3 few-shot 基本追平甚至略超当时的监督式翻译系统。

但讲义也指出：

English → foreign language 的结果明显差很多，因为 GPT-3 主要是英语语言模型。

通俗理解：

GPT-3 更像一个英语能力极强的人。

它能很好地把外语“理解成英语”，但从英语精准写成外语，就没那么稳。

这背后其实说明：

模型能力和训练语料分布高度相关。

它见过什么多，就擅长什么；见过什么少，就弱一些。

9. 算术：表现惊人，但不能说真正理解数学

讲义还测试了 GPT-3 做 2 到 5 位数的加减乘法。

Prompt 类似：

Q: What is 556 plus 497?

A: 1053

结果显示，模型规模越大，算术表现越好。175B 的 GPT-3 在一些简单加减法上表现不错，但整体并不完美。

讲义的表述很克制：

它不能说完全“理解了算术”，但表现出人意料地好。

通俗理解：

GPT-3 不是像计算器一样严格按算法算。

它更像通过大量文本学到了一些数字模式和计算痕迹，所以简单题能做，复杂题容易错。

这也是为什么现在真实产品里做计算，一般会让模型调用工具，而不是让模型自己硬算。

10. 新闻生成：人类很难分辨真假

新闻生成任务是：

给标题和副标题，让 GPT-3 生成一篇新闻。

然后让人类判断这篇文章是人写的，还是机器写的。

结果很震撼：

人类区分 human vs machine 的准确率只有 52%，几乎接近随机猜。

某个例子里，人类正确猜出是机器写的比例只有 12%。

这说明 GPT-3 在长文本生成上已经非常像人类写作。

但这也带来风险：

它可以生成看起来非常真实的文章，即使内容未必可靠。

所以这部分不仅是能力展示，也是风险提示。

11. Novel tasks：新奇任务体现 GPT-3 的泛化能力

讲义还列了很多“一次性任务”。

比如：

11.1 使用新造词

给一个虚构单词和定义：

```
To “screeg” something is to swing a sword at it.
```

让模型造句：

```
We screeged the tree with our swords.
```

这说明 GPT-3 不只是背诵固定词汇，而是能在上下文中临时理解一个新符号的含义。

11.2 语法纠错

Prompt 给出几组：

```
Poor English input: I eated the purple berries.  
Good English output: I ate the purple berries.
```

然后模型可以继续把坏英语改成好英语。

这类任务非常像今天我们日常用大模型做的事情：

润色、改写、翻译、纠错、风格转换、格式转换。

这些任务不一定需要专门训练，只要 prompt 写得清楚，模型就能做得不错。

12. 讲义最重要的结论

这讲最后的 summary 非常关键，可以概括为五句话：

1. GPT-3 被测试在非常广泛的任务上

包括标准 NLP benchmark，也包括很多奇怪但有趣的 demo。

2. GPT-3 的表现非常不均衡

有些任务非常强，比如语言建模、LAMBADA、德译英、新闻生成。

有些任务一般，比如复杂问答、抽象推理、算术。

3. 模型越大，效果越好

讲义多次展示：参数规模从 0.1B 到 175B 增长时，很多任务表现明显提升。

这就是 scaling law 在能力层面的体现。

4. prompt 里示例越多，效果通常越好

Zero-shot < One-shot < Few-shot。

通俗地说：

你不给例子，它只能猜你的意图；
你给几个例子，它就更容易模仿你的格式和判断标准。

5. 为什么这套方法能工作？没人完全知道

这是讲义最后一句非常重要的话：

Why does this work? No one knows.

这不是说完全没有理论，而是说：

我们知道现象上它有效，但对大模型内部到底如何形成这些能力，还没有完全解释清楚。

13. 用大白话理解这讲

如果把 GPT-3 比作一个人，它不是这样训练出来的：

这是问答题，你专门学问答。
这是翻译题，你专门学翻译。
这是语法纠错题，你专门学纠错。

它更像是：

读了海量文本，学会了语言世界里的大量模式。
然后你通过 prompt 告诉它：“现在请你按这个格式做事。”
它就能临时把自己变成问答器、翻译器、纠错器、文章生成器。

所以 GPT-3 的能力不是传统意义上的“一个模型对应一个任务”，而是：

一个通用语言模型，通过上下文临时适配很多任务。

这就是大模型范式 and 传统 NLP 范式的根本差别。

14. 对你学习大模型的启发

这讲其实是在帮你建立一个非常重要的认知框架：

传统 NLP 时代

每个任务都要专门训练模型：

- 问答模型
- 翻译模型
- 摘要模型
- 情感分类模型
- 语法纠错模型

GPT-3 之后的大模型时代

一个基础模型，通过 prompt 适配不同任务：

- 基础模型 + prompt → 问答
- 基础模型 + prompt → 翻译
- 基础模型 + prompt → 摘要
- 基础模型 + prompt → 写作
- 基础模型 + prompt → 纠错

这就是 foundation model 的雏形。

核心概念：

概念	你需要理解到什么程度
Language modeling	大模型本质是预测下一个 token
Adaptation	如何把语言模型变成任务模型
Prompting	为什么 prompt 能临时定义任务
In-context learning	为什么示例能影响模型输出
Few-shot learning	少量样例如何提升性能
Benchmark	如何评价模型能力
Scaling	为什么模型变大后能力增强
Limitation	为什么模型有时强、有时弱、有时胡说

15. 总结

《Capabilities》这讲的核心不是说 GPT-3 已经“无所不能”，而是说明：

一个只经过语言建模训练的大模型，在没有针对具体任务训练的情况下，居然能通过 prompt 在大量任务上获得可用甚至很强的表现。

这标志着 NLP 从“为每个任务训练专门模型”，转向“用一个通用基础模型适配多种任务”。

但同时，这讲也提醒我们：

GPT-3 的能力是广泛但不稳定的；它可以生成很像真的内容，但不保证事实可靠；它能做算术，但不是计算器；它能回答问题，但不是数据库；它能翻译，但受训练语料分布影响很大。

所以理解 GPT-3 capabilities 的关键，是同时看到两面：

一方面，它展示了大模型作为通用智能接口的潜力；另一方面，它也暴露了大模型在可靠性、事实性、任务稳定性上的限制。