

# 1. RAG 是什么？

**检索增强生成**，英文为 **Retrieval-Augmented Generation**，简称 **RAG**，是一种提升生成式 AI 模型准确性与可靠性的技术。它的核心做法是：让大语言模型在回答问题时，不只依赖模型参数中已有的通用知识，而是能够从特定、相关、可信的数据源中检索信息，再结合这些信息生成回答。

换句话说，RAG 弥补了大语言模型自身工作机制中的一个缺口。

大语言模型本质上是神经网络，通常用参数规模来衡量。模型参数可以理解为模型对人类语言模式的压缩记忆，也就是文章中所说的 **parameterized knowledge**，**参数化知识**。这种知识让大模型能够回答很多通用问题，但当用户需要 **有依据、可追溯、基于特定资料的权威答案** 时，仅靠参数化知识是不够的。

RAG 的价值就在于：它可以把大语言模型与外部知识源连接起来，让模型在生成答案前先检索相关资料。

---

## 2. 文章用“法庭”类比解释 RAG

文章开头用了一个很形象的比喻。

法官可以基于自己对法律的一般理解审理案件，但遇到医疗事故、劳动纠纷等专业案件时，法官往往需要书记员去法律图书馆查找具体判例和先例。

在这个类比中：

- **大语言模型像法官**：拥有广泛的通用知识；
- **外部知识库像法律图书馆**：存放具体、专业、最新的资料；
- **RAG 像书记员**：负责把相关资料检索出来，交给模型参考；
- **最终回答像判决意见**：既有模型的语言组织能力，也有具体资料作为支撑。

因此，RAG 的本质不是让模型“凭空知道更多”，而是让模型在回答前能够“查资料”。

---

## 3. RAG 为什么重要？

文章强调，RAG 的重要性主要体现在三个方面。

第一，**提高准确性**。

当模型面对专业问题、企业内部知识、最新信息或特定领域资料时，RAG 可以把相关信息检索

出来，减少模型仅凭通用训练知识回答的风险。

### 第二，增强可信度。

RAG 可以让模型引用信息来源，就像论文中的脚注一样。用户可以检查模型回答依据了哪些资料，从而提升信任感。

### 第三，减少幻觉。

所谓 **hallucination**，**幻觉**，是指模型生成看起来很合理但实际上错误的答案。RAG 通过把答案锚定在可检索资料上，可以降低模型编造信息的概率。

---

## 4. RAG 与重新训练模型的区别

文章指出，RAG 的一个重要优势是：它比重新训练模型更快、更便宜、更灵活。

如果企业想让大语言模型掌握新的知识，理论上可以重新训练或微调模型，但这通常成本高、周期长、维护复杂。

而 RAG 的思路是：不一定要把所有知识都塞进模型参数里，而是把知识放在外部知识库中，需要时再检索。

这带来几个好处：

- 不需要频繁重新训练模型；
- 可以随时更新知识库；
- 可以快速替换数据源；
- 更适合企业内部文档、政策手册、技术手册、日志、视频资料等场景。

这也是为什么 RAG 被广泛用于企业 AI 助手、客服支持、员工培训、研发提效、金融分析、医疗辅助等场景。

---

## 5. RAG 是如何工作的？

文章对 RAG 的流程做了一个高层次解释。

典型 RAG 流程可以概括为：

**用户提问 → 查询向量化 → 检索知识库 → 返回相关资料 → 大模型生成答案**

更具体地说：

1. 用户向大语言模型提出问题；

- 2. 系统使用 **embedding model**，**嵌入模型**，把用户的问题转换成机器可以理解的数值形式；
- 3. 这个数值形式通常叫作 **embedding**，**嵌入**，或者 **vector**，**向量**；
- 4. 系统将这个查询向量与知识库中的向量进行相似度匹配；
- 5. 匹配到相关内容后，从知识库中取回资料；
- 6. 检索出的资料会被转换成人类可读文本，并传给大语言模型；
- 7. 大语言模型结合检索资料和自身语言生成能力，输出最终答案；
- 8. 在理想情况下，答案还可以附带引用来源。

这里涉及几个关键专业词汇：

| 英文术语                           | 推荐中文表达    | 含义                   |
|--------------------------------|-----------|----------------------|
| Retrieval-Augmented Generation | 检索增强生成    | 通过检索外部知识增强生成式模型      |
| LLM                            | 大语言模型     | Large Language Model |
| embedding                      | 嵌入 / 向量表示 | 将文本转换为数值向量           |
| vector database                | 向量数据库     | 存储文本向量，支持相似度检索       |
| knowledge base                 | 知识库       | 存放企业文档、资料、数据源等       |
| hallucination                  | 幻觉        | 模型生成看似合理但错误的信息       |
| reranking model                | 重排序模型     | 对检索结果重新排序，提高相关性      |
| parameterized knowledge        | 参数化知识     | 存储在模型参数中的知识          |

## 6. RAG 需要保持知识源更新

文章还特别强调，RAG 的后台系统需要持续更新知识库。

当新的知识库或更新后的资料出现时，嵌入模型会持续创建和更新机器可读索引，也就是通常所说的向量数据库。

这意味着，RAG 系统的关键不只是“接一个数据库”，而是要有完整的数据处理流程：

**资料接入 → 清洗切分 → 向量化 → 建立索引 → 检索 → 重排序 → 生成回答 → 引用来源**

如果知识库不更新，RAG 的回答也会变旧。因此，RAG 系统的质量不仅取决于大模型，也取决于数据管道、检索质量、向量数据库、重排序模型和知识库维护机制。

## 7. RAG 的应用场景

文章列举了多个应用方向。

例如，医疗领域中，如果生成式 AI 模型连接到医学索引，就可以辅助医生或护士查询专业信息。

金融领域中，如果 AI 助手连接到市场数据，就可以帮助分析师更好地理解市场变化。

企业也可以把技术手册、政策文件、视频资料、日志、内部知识库等资料转化为大模型可检索的知识源，用于：

- 客户支持；
- 现场服务支持；
- 员工培训；
- 企业研究；
- 开发者生产力提升；
- 企业级 AI 助手；
- Agentic AI，即智能体式 AI 应用。

文章最后提到，生成式 AI 的未来会走向 **agentic AI**，也就是大语言模型、知识库、工具和任务流程被动态编排，形成更自主的 AI 助手。

---

## 8、总结

**RAG 是让大语言模型从“凭记忆回答”走向“查资料后回答”的关键技术，它通过连接外部知识库，提高生成式 AI 的准确性、可信度和可验证性。**

更完整地说：

1. 大语言模型本身拥有通用知识，但不天然掌握最新、私有、专业或特定场景的信息。
2. RAG 通过检索外部知识源，把相关资料提供给模型，使模型能够生成更有依据的答案。
3. RAG 相比重新训练模型更灵活、更便宜，也更适合企业知识库、行业资料和实时数据场景。
- ==
4. RAG 的关键技术栈包括嵌入模型、向量数据库、知识库、检索系统、重排序模型和大语言模型。
5. RAG 可以减少幻觉，提高答案的可追溯性，因为模型可以引用检索到的来源。
6. RAG 是企业级 AI 助手和 Agentic AI 的基础能力之一，因为真正有价值的 AI 系统往往需要连接企业内部数据、外部知识和工具。