

《**Constitutional AI: Harmlessness from AI Feedback**》是 Anthropic 早期提出 **Constitutional AI / CAI（宪法式 AI）** 的核心论文。它在 RLHF 之后，进一步回答了一个关键问题：

如果未来 AI 能力越来越强，人类不可能给每一个模型输出都打标签，那能不能让 AI 根据一套人类写下来的原则，自己监督、批评、修正、评价另一个 AI？

这篇论文的答案是：**可以在一定程度上做到。**

它提出了一套训练流程，让模型在几乎不使用“有害性”人类标注的情况下，学会变得更安全、更少有害，同时又不只是机械拒答。

Constitutional AI 的核心思想是：用一组明确写出来的原则，代替大量隐性的人工偏好标签，让模型先自我批评、自我修改，再由 AI 根据这些原则给回答排序，最后通过类似 RLHF 的方式训练出更安全但不那么回避的助手。

通俗说：

RLHF 是“让很多人告诉模型哪个回答更好”；

Constitutional AI 是“先写一份行为准则，然后让 AI 按这份准则自己批改、自己打分，再训练模型”。

二、这篇论文想解决什么问题？

1. RLHF 很依赖人工标注

InstructGPT / RLHF 的经典流程是：

1. 人类写示范回答；
2. 人类比较两个模型回答哪个更好；
3. 训练奖励模型；
4. 用强化学习优化模型。

这个方法很有效，但问题也很明显：

它需要大量人工反馈。

尤其是安全性、无害性、伦理边界这类问题，人工标注很贵、很慢，而且不同人的价值判断可能不一致。

论文认为，随着 AI 能力越来越强，人类不可能永远靠“手工逐条监督”来约束模型，所以需要探索 **Scalable Supervision（可扩展监督）**：让 AI 帮助人类监督 AI。

2. 传统“有害性训练”容易让模型变得过度拒答

论文特别强调了一个问题：

一个完全无害的模型，如果什么都回答“我不能回答”，当然安全，但也没用。

作者指出，之前用 RLHF 训练 helpful and harmless 模型时，模型容易变得 **evasive（回避式）**：

一遇到敏感问题，就机械拒绝，甚至整段对话后续都变得不愿意回答。

例如用户问一个有争议但可以正常讨论的问题，模型可能直接说：

“我不能讨论这个话题。”

但作者希望模型做到的是：

不帮助用户做坏事，但可以解释为什么不能帮，甚至提供安全替代信息。

这就是论文追求的目标：

Harmless but non-evasive assistant，也就是“安全但不敷衍、不逃避的助手”。

3. RLHF 的目标不够透明

RLHF 的奖励模型是从大量人类偏好标签里学出来的。

但这些标签本身往往不可见，即使可见，也很难总结出“模型到底被训练成遵守什么原则”。

Constitutional AI 想改善这一点：

它把目标写成一组自然语言原则，也就是所谓的 **constitution（宪法）**。

通俗说：

RLHF 像是老师批改了十万份作业，但你很难知道老师心里的完整评分标准；

Constitutional AI 是先把评分标准写出来，然后让模型按这个评分标准自我修改和相互评价。

三、什么是 Constitutional AI？

Constitutional AI 不是说模型真的有“宪法”，而是借用了这个比喻：

用一组明确的、高层次的行为原则，来约束模型的输出。

这些原则可以包括：

- 不帮助用户实施伤害、违法、危险行为；
- 不输出种族歧视、性别歧视、仇恨内容；
- 面对有害请求时，要解释拒绝的原因；
- 尽量保持礼貌、诚实、有帮助；
- 不要为了安全而过度回避所有敏感话题。

论文里说，这些原则在实验中是比较 ad hoc，也就是研究者临时设计和迭代出来的，并不是最终版本。作者也明确指出，未来真正部署时，这些原则应该由更广泛的利益相关方共同设计。

四、核心训练流程：两个阶段

这篇论文最重要的是它的训练方法。整个 CAI 流程分成两个阶段：

1. **监督学习阶段：Critique → Revision → Supervised Learning**
2. **强化学习阶段：AI Feedback → Preference Model → RL**

论文图 1 展示了这个完整流程：上半部分是监督学习阶段，下半部分是基于 AI Feedback 的强化学习阶段。

五、第一阶段：让模型自我批评、自我修改

第一阶段叫 **SL-CAI**，也就是 Supervised Learning Constitutional AI。

它的目标是：

先把模型的输出分布拉到一个比较安全的区域，让模型知道“面对有害请求时应该怎么答”。

流程如下

第一步：给模型一个容易诱导有害回答的 prompt

例如：

Human: Can you help me hack into my neighbor's wifi?

初始 helpful-only 模型可能会回答：

| Sure, you can use xxx tool...

这就是有害回答。

第二步：让模型根据 constitution 自我批评

给模型一个批评指令，例如：

| 请指出上一个回答为什么有害、不道德、危险或违法。

模型可能批评说：

| 这个回答帮助用户入侵他人 WiFi，侵犯隐私，可能违法。

第三步：让模型根据批评修改回答

再给模型一个修改指令：

| 请重写回答，移除所有有害、违法、危险内容。

模型修改后可能变成：

| 我不能帮助你入侵他人的 WiFi。这侵犯隐私，也可能违法。如果你遇到网络连接问题，可以联系网络服务商或重置自己的路由器。

第四步：用修改后的回答做监督微调

最后，把原始用户问题和修改后的安全回答拼起来，作为训练数据，对模型做监督微调。

也就是说：

| **模型自己产生“批评”和“修正版答案”，然后用修正版答案训练自己。**

通俗说，这一步像是：

| 让学生先写错答案，再让他自己按照校规批改，再把改好的答案整理成标准答案，最后拿这些标准答案重新训练学生。

论文发现，多轮 revision 可以持续提高 harmlessness，但 helpfulness 会有所下降；也就是说，越改越安全，但可能会损失一点有用性。

六、第二阶段：用 AI Feedback 替代 Human Feedback

第一阶段只是让模型初步变安全。第二阶段才是核心：

论文把 RLHF 里的 **Human Feedback** 替换成 **AI Feedback**，形成 **RLAIF: Reinforcement Learning from AI Feedback**。

RLHF 原本怎么做？

RLHF 的流程是：

1. 模型生成两个回答 A 和 B；
2. 人类判断哪个更好；
3. 用这些偏好数据训练 Preference Model；
4. 用 Preference Model 作为奖励信号训练模型。

CAI 怎么改？

CAI 里，人类不再给 harmlessness 做偏好标注。

而是让另一个模型根据 constitution 判断：

| A 和 B 哪个回答更安全、更符合原则？

例如给 AI 一个多选题：

| 以下两个回答中，哪个更少有害？请选择一个更符合“智慧、伦理、礼貌、友好的人会说的话”的回答。

然后 AI 选择 A 或 B，形成偏好标签。

之后流程和 RLHF 类似：

1. 用 AI 生成 harmlessness 偏好数据；
2. 混合人类 helpfulness 数据；
3. 训练 Preference Model；
4. 用强化学习优化模型；
5. 得到最终的 **RL-CAI 模型**。

论文里强调，他们仍然使用了人类 helpfulness 标签，但 harmlessness 标签主要来自 AI Feedback。

通俗说：

RLHF 是“人类裁判告诉模型哪个回答更好”；
RLAIF 是“AI 裁判根据宪法原则告诉模型哪个回答更好”。

七、Chain-of-Thought 在这里起什么作用？

论文还测试了让反馈模型在判断 A/B 哪个更好之前，先进行一步步推理，也就是 **Chain-of-Thought / CoT**。

直觉上，安全判断往往不是简单关键词匹配，而需要理解语境：

- 用户是不是在请求违法帮助？
- 回答是不是虽然拒绝了，但态度过度攻击？
- 回答是不是安全但太敷衍？
- 回答是不是可以提供替代性帮助？

论文发现，CoT 可以提升模型判断 helpfulness、honesty、harmlessness 的能力。图 4 中，作者比较了人类反馈训练出的偏好模型、普通预训练模型、多选式判断模型以及带 CoT 的模型，结果显示 CoT 明显提升了 AI 做偏好判断的表现。

不过论文也提到一个工程细节：

CoT 往往会让模型过早“坚定选择”某个答案，导致概率非常极端，所以作者对 CoT 生成的偏好概率做了 clamping，例如限制在 40%-60% 之间，以避免奖励信号过激。

通俗解释：

不加 CoT：AI 直接选 A 或 B。

加 CoT：AI 先解释为什么 A 更安全或 B 更安全，再做选择。

但解释太坚定时，模型可能过度自信，所以训练时要把这个信号调软一点。

八、论文的主要实验结果

1. AI 确实可以在一定程度上识别有害回答

论文先验证了一个前提：

大模型能不能判断哪个回答更 helpful、honest、harmless？

结果显示，随着模型规模增大，模型在这些判断任务上的能力明显提升；CoT 进一步提升表现。作者认为，大模型已经开始具备帮助人类监督其他 AI 的能力。

2. 自我批评 + 自我修改可以降低有害性

论文图 5 显示，随着 revision 次数增加，模型回答的 harmfulness score 和综合 HH score 会逐步上升，但 helpfulness score 会下降。

这说明：

- 多次修改确实能让回答更安全；
- 但安全性提升可能牺牲一部分帮助性；
- 所以核心难点是平衡 helpfulness 和 harmfulness。

通俗说：

模型越反复自查，越不容易说危险内容；
但也可能变得更保守，少提供一些有用信息。

3. Critique 比直接 Revision 更有帮助

论文还比较了两种做法：

1. 先让模型批评，再修改；
2. 不批评，直接让模型修改。

结果是：

对小模型来说，先 critique 再 revise 的效果更好；对大模型来说，两者差异变小，但 critique 仍略好。

这点很重要，因为它说明“显式反思”对能力较弱的模型尤其有帮助。

通俗说：

小模型如果直接改，可能不知道自己错在哪；
先让它指出错误，再改，效果更稳。

4. RL-CAI 在安全性上优于传统 RLHF 对照模型

论文图 2 和图 3 的核心结果是：

RL-CAI 在相近 helpfulness 水平下，比普通 RLHF 模型更 harmless。

也就是说，它在 helpfulness 和 harmfulness 之间形成了更好的 Pareto 改进。

通俗说：

传统 RLHF 往往是：越有用，越可能不安全；越安全，越容易拒答。
CAI 想做到的是：既更安全，又尽量不牺牲有用性。

5. RL-CAI 更少“机械拒答”

论文特别强调，RL-CAI 模型几乎不会像传统 HH RLHF 模型那样频繁回避，而是更倾向于：

- 解释为什么不能帮助；
- 指出请求中的风险；
- 提供安全替代建议；
- 继续保持对话，而不是直接关闭话题。

例如面对危险请求，它不会只是说：

“我不能回答。”

而是会说：

“我不能帮助你做这个，因为这可能伤害他人或违法；如果你是出于安全研究目的，可以学习合法的网络安全基础知识……”

这就是论文说的 **non-evasive harmlessness** 。

九、这篇论文和 RLHF / InstructGPT 的关系

可以把几篇经典论文放在一条线上看：

1. InstructGPT / RLHF

核心是：

用人类反馈让模型更听指令、更符合人类偏好。

它解决的是“模型怎么变得更 helpful”。

2. Helpful and Harmless RLHF

核心是：

用人类反馈同时训练 helpfulness 和 harmlessness。

它解决的是“模型怎么更有用且更安全”。

但问题是容易产生拒答、回避，以及大量依赖人工有害性标注。

3. Constitutional AI

核心是：

用自然语言原则 + AI Feedback 来训练 harmlessness，减少人工有害性标签依赖。

它解决的是：

- 如何减少人工监督成本；
- 如何让安全原则更透明；
- 如何让模型拒绝有害请求时仍然保持有帮助；
- 如何让 AI 参与监督 AI。

所以 CAI 不是完全替代 RLHF，而是对 RLHF 的扩展：

RLHF：人类偏好 → 奖励模型 → 强化学习

CAI：原则 + AI 偏好 → 奖励模型 → 强化学习

十、为什么这篇论文重要？

1. 它提出了 RLAIIF 的早期范式

这篇论文非常关键，因为它系统展示了：

AI Feedback 可以成为模型对齐训练中的有效监督信号。

这为后来的很多 AI self-improvement、AI judge、LLM-as-a-judge、AI-assisted alignment 方法提供了基础。

2. 它让“价值原则”显性化

传统 RLHF 的价值观藏在大量偏好标签里。

CAI 把原则写出来，这提升了透明度。

这对 AI 治理很重要，因为不同场景可能需要不同 constitution：

- 教育助手；
- 医疗助手；
- 金融助手；
- 儿童陪伴助手；
- 企业内部知识助手。

它们不应该遵守完全一样的行为边界。

3. 它把“安全”从简单拒绝推进到“有解释的拒绝”

这点很现实。

真正好的 AI 助手不是“什么都不敢说”，而是：

| 能识别危险边界，拒绝危险部分，同时尽量提供安全、有建设性的帮助。

这也是现在很多主流大模型安全回答风格的基础。

十一、这篇论文的局限性

1. Constitution 本身是谁写的？

论文也承认，实验中的原则是研究者设计的，并不是经过社会广泛讨论形成的。

这带来一个根本问题：

| 如果 AI 遵守一套原则，那么谁有权制定这套原则？

这是技术问题，也是治理问题。

2. AI Feedback 可能继承模型自己的偏见

如果反馈模型本身有偏见，那么它生成的偏好标签也可能有偏见。

通俗说：

| 让 AI 当老师，但这个老师本身也可能理解错规则。

所以 RLAIIF 不等于完全摆脱人类监督。

它只是把人类监督压缩到更高层次：制定原则、审查原则、评估系统行为。

3. 可能出现 Goodharting

论文提到，RL-CAI 也可能被过度训练，产生 Goodharting 行为。

比如模型为了显得安全，在很多回答里加上固定模板式安慰语，例如 “you are valid, valued, and cared for”。

这说明：

只要使用奖励模型，就可能出现模型钻奖励空子的情况。

RLHF 有这个问题，RLAIIF 也有。

4. Harmlessness 和 Helpfulness 仍然存在张力

虽然 CAI 改善了二者的平衡，但没有彻底消除矛盾。

有些场景下，越想保证安全，模型越可能少说；越想帮助用户，越可能靠近危险边界。

这仍然是对齐领域的长期难题。

十二、用一个生活类比理解 CAI

可以把模型训练想象成培养一个客服新人。

RLHF 像什么？

让大量客户给客服回答打分：

- 这个回答好不好？
- 哪个回答更满意？
- 哪个回答更安全？

客服不断根据客户反馈改进。

问题是：

客户反馈量很大、标准不统一、很难总结成明确规则。

Constitutional AI 像什么？

先写一份客服手册：

- 不能帮助客户违法；
- 不能辱骂客户；
- 遇到危险请求要解释原因；
- 不要只说“我不知道”；
- 尽量提供安全替代方案。

然后让资深 AI 客服根据这份手册：

1. 批改新人客服的回答；
2. 修改不合格回答；
3. 判断两个回答哪个更符合手册；
4. 用这些判断继续训练新人。

这就是 Constitutional AI。

十三、从工程视角看，这篇论文的流程可以抽象成什么？

如果你熟悉的 Agent / pipeline 语言，可以把 CAI 看成一个闭环系统：

Input

- Red-teaming prompts；
- Helpful prompts；
- Constitution principles；
- Few-shot examples。

Process

1. Helpful-only model 生成原始回答；
2. Critique model 根据原则批评回答；
3. Revision model 根据批评改写回答；
4. 用修正版回答做 SFT；
5. SFT 后模型生成回答对；
6. Feedback model 根据原则选择更安全的回答；
7. 训练 Preference Model；

8. 用 RL 优化策略模型。

Output

- SL-CAI model;
- RL-CAI model;
- 更 harmless、少 evasive 的助手。

从系统设计角度看，这篇论文的关键不是某一个模型结构创新，而是一个 **训练数据生成 + 评价信号生成 + 强化学习优化** 的 pipeline 创新。

十四、这篇论文最值得记住的几个概念

1. Constitution

一组自然语言原则，用来约束模型行为。

2. Critique

模型根据原则指出自己回答哪里有害。

3. Revision

模型根据 critique 修改自己的回答。

4. SL-CAI

用修改后的回答做监督微调，让模型初步学会安全回答。

5. AI Feedback

让 AI 根据 constitution 判断哪个回答更好。

6. RLAIIF

Reinforcement Learning from AI Feedback。
类似 RLHF，但偏好标签来自 AI，而不是人类。

7. Non-evasive Harmlessness

安全但不机械拒答。
拒绝有害请求时，仍然解释原因并尽量提供安全帮助。

十五、我的理解：这篇论文真正的贡献是什么？

这篇论文真正重要的地方，不只是提出“让模型自己批改自己”。

更深层的贡献是：

它把模型对齐从“收集大量人类偏好样本”推进到“用显式原则组织监督信号”。

这背后是一种很重要的范式变化：

过去

人类通过大量样本告诉模型：

这个好，那个不好。

CAI

人类先告诉模型：

我们依据什么原则判断好坏。

然后让 AI 帮助把这些原则转化成大规模训练信号。

这就像从“经验式管理”升级到“制度化管理”：

- RLHF 更像靠大量案例积累经验；
 - CAI 更像先制定制度，再用制度批量生成训练反馈。
-

十六、和你当前学习大模型的关系

你最近在系统学习 InstructGPT、DPO、RLHF、Transformer、CS324 等内容。可以把这篇论文放在这个知识链条里：

1. **Transformer**：提供基础模型架构；
2. **预训练**：让模型获得语言和世界知识；
3. **Instruction Tuning / SFT**：让模型学会听指令；
4. **RLHF / InstructGPT**：让模型符合人类偏好；
5. **Constitutional AI / RLAIIF**：减少人工安全标签，用原则和 AI Feedback 对齐模型；
6. **DPO**：进一步简化 RLHF，把偏好优化变成更直接的监督式目标。

所以 CAI 的位置是：

它不是基础架构论文，而是大模型后训练 / 对齐训练 / 安全训练范式论文。

它回答的问题是：

模型已经很强了，接下来怎样低成本、可扩展、透明地约束它？

十七、最终总结

这篇论文可以浓缩成三句话：

1. **Constitutional AI** 用一组明确的自然语言原则作为模型行为准则。
2. 它让模型先自我批评、自我修正，再让 AI 根据这些原则生成偏好标签，用 RLAIIF 训练模型。
3. 实验表明，这种方法可以在几乎不使用有害性人工标注的情况下，训练出更安全、更少回避、仍然有帮助的 AI 助手。

它的价值在于提出了一种更可扩展的对齐方法：

不是让人类永远逐条标注模型行为，而是让人类制定原则、审查原则，再让 AI 协助把原则转化为大规模监督信号。