

这是InstructGPT / RLHF 的经典论文，核心是：单纯把语言模型做大，并不能自然让它更会“听懂人话、按人类意图办事”；要让模型更有用、更诚实、更安全，需要把“人类偏好”显式引入训练流程。论文提出的做法就是：先让人类示范好答案，再让人类比较多个模型答案的好坏，最后用强化学习让模型朝“人更喜欢的回答方式”优化。

1. 这篇论文解决的核心问题是什么？

论文的出发点很简单，但非常关键：

GPT-3 这类大模型的预训练目标，是“预测下一个 token”，不是“帮助用户完成任务”。

也就是说，预训练阶段的模型学到的是：

给定前面的文本，接下来最可能出现什么文字？

但用户真正想要的是：

请理解我的意图，按照我的要求，给我一个有帮助、真实、尽量安全的回答。

这两个目标并不完全一致。

所以论文说，传统语言模型存在 **misalignment，不对齐** 的问题。比如模型可能：

- 1. 不按用户指令来；
- 2. 编造事实；
- 3. 输出有害、偏见或毒性内容；
- 4. 明明用户问的是一个具体问题，它却继续写网页风格、续写风格或乱补文本。

通俗说：

预训练模型像是一个“超级会接话的人”，但不一定是一个“靠谱的助手”。

InstructGPT 要做的事情，就是把“会接话的人”训练成“会按要求帮你做事的助手”。

论文将对齐目标概括为三个词：

Helpful、Honest、Harmless：

目标	含义	通俗解释
Helpful	有帮助	能解决用户的问题
Honest	诚实	不瞎编，不误导

目标	含义	通俗解释
Harmless	无害	尽量不输出危险、有毒、歧视性内容

论文文明确说，它们的目标是让模型按照用户意图行动，包括显性意图，比如“按照指令做事”，也包括隐性意图，比如“保持真实、避免有害内容”。

2. 为什么“模型越大”不等于“越会听指令”？

这篇论文最经典的发现之一是：

1.3B 参数的 InstructGPT，竟然比 175B 参数的 GPT-3 更受人类标注员喜欢。

也就是说，一个经过人类反馈微调的小模型，可以打败一个大很多的原始模型。论文中提到，1.3B InstructGPT 的输出优于 175B GPT-3，尽管参数量少了 100 倍以上；175B InstructGPT 相比 175B GPT-3，也有非常明显的人类偏好优势。

通俗理解：

GPT-3 像一个读了全网内容的“知识巨人”，但它的训练目标不是“服务用户”。
InstructGPT 像是在这个巨人基础上，接受了“人类助理培训”。
训练之后，即使模型小一些，也可能更像一个真正能帮你工作的助手。

这说明一个非常重要的观点：

能力和对齐不是一回事。
模型更大，代表它可能更有语言能力和知识容量；
但它是否愿意、是否知道如何按照人的意图回答，需要额外训练。

这也是后来 ChatGPT、Claude、Gemini 等对话式模型的基础思想之一。

3. InstructGPT 的训练流程：三步走

论文里的方法可以概括为三步：

1. **SFT：监督微调**
2. **RM：奖励模型训练**
3. **PPO：基于奖励模型做强化学习**

论文第 3 页的 Figure 2 就是这三步流程图。图里展示了从人类示范，到人类排序，再到用 PPO 优化模型的完整闭环。

下面逐步解释。

第一步：SFT，Supervised Fine-Tuning，监督微调

这一步做的是：

收集人类写出来的“理想答案”，然后让 GPT-3 模仿这些答案。

具体流程是：

1. 给人类标注员一个用户 prompt；
2. 标注员写出一个高质量回答；
3. 用这些 prompt-answer 数据微调 GPT-3。

通俗理解：

就像训练一个新人助理。

你先不让他自由发挥，而是给他看很多“标准答案”：

“用户这样问，你应该这样答。”

看多了之后，他开始学会什么样的回答像一个助手。

这一阶段得到的模型叫 **SFT model**。

但 SFT 有一个问题：

它只告诉模型“一个好答案长什么样”，没有告诉模型“两个答案哪个更好”。

比如同一个问题，有三个答案：

- A：简洁准确；
- B：啰嗦但还行；
- C：看似自信但编造事实。

SFT 只能模仿人类写的答案，不能很好地学习这种细腻的偏好排序。

所以需要第二步。

第二步：RM，Reward Model，奖励模型

这一步做的是：

让模型生成多个答案，然后请人类标注员排序：哪个最好，哪个最差。
再训练一个奖励模型，让它学会预测人类更喜欢哪个答案。

论文中，标注员会看到同一个 prompt 下的多个模型输出，比如 A、B、C、D，然后对它们进行排序。之后研究者用这些排序数据训练一个 **Reward Model，奖励模型**。

奖励模型的作用是：

输入：用户 prompt + 模型回答
输出：一个分数
分数越高，代表它越可能被人类喜欢。

通俗理解：

SFT 是“老师亲自写范文，让学生模仿”。
RM 是“老师不亲自写答案，而是给学生作文打分”。
以后学生写出一个答案，奖励模型就能自动判断：这个答案大概能得多少分。

这里非常关键：

奖励模型不是判断“客观真理”的模型，而是判断“人类标注员更偏好哪个回答”的模型。

所以它学到的是一组人类偏好，包括：

1. 是否有帮助；
2. 是否遵循指令；
3. 是否合适；
4. 是否更真实；
5. 是否更安全；
6. 是否表达更自然。

论文也很诚实地指出：这并不是对齐到某种抽象的“全人类价值”，而是**对齐到研究团队和标注员群体表达出来的偏好**。

第三步：PPO，用强化学习优化模型

有了奖励模型之后，第三步就是：

让语言模型不断生成答案，然后用奖励模型打分。
如果答案得分高，就强化这种回答方式；
如果得分低，就减少这种回答方式。

这一步使用的是 **PPO，Proximal Policy Optimization**，一种强化学习算法。

通俗理解：

模型像一个学生，奖励模型像一个自动评分老师。
学生每写一次答案，老师给一个分数。
学生慢慢学会：什么样的回答更容易拿高分。

但这里有一个风险：

模型可能会“钻奖励模型的空子”。

比如奖励模型喜欢礼貌、详细、谨慎，模型就可能变得：

- 1. 过度礼貌；
- 2. 过度解释；
- 3. 不敢直接回答；
- 4. 喜欢用模糊话术；
- 5. 表面很安全，但实际没解决问题。

所以论文加入了一个重要机制：**KL penalty** 。

它的作用是：

不要让 PPO 训练后的模型偏离原来的 SFT 模型太远。

通俗说：

可以让学生根据评分老师改进，但不能让学生为了讨好评分系统变得太怪。

4. PPO 和 PPO-ptx 的区别是什么？

论文里有两个相关模型：

模型	含义
PPO	只用奖励模型做强化学习
PPO-ptx	在 PPO 的同时，混入一部分预训练数据目标

论文默认说的 InstructGPT，通常指的是 **PPO-ptx** 。

为什么要加 ptx？

因为作者发现，单纯用 RLHF 优化之后，模型在一些公开 NLP benchmark 上会退步，比如 SQuAD、DROP、HellaSwag、翻译任务等。这就是论文说的 **alignment tax**，**对齐税** 。

通俗理解：

你把一个人训练成“特别会服务用户的客服”，他可能在某些考试题上反而退步了。
因为他的行为风格被调整了，不再是原来那个单纯预测文本的模型。

PPO-ptx 的做法是：

- 一边让模型学习人类偏好，
- 一边让它不要忘掉预训练阶段学到的通用语言能力。

类似于：

新人助理接受服务培训的同时，也继续保持原来的专业知识训练。

论文发现，这种方法可以显著缓解对齐带来的 benchmark 性能下降，同时不明显损害人类偏好得分。

5. 训练数据来自哪里？

论文的数据主要来自两类：

- 标注员自己写的 prompts
- OpenAI API Playground 用户提交的 prompts

论文说明，API prompt 涵盖了很多真实使用场景，包括：

用途	占比
Generation 生成	45.6%
Open QA 开放问答	12.4%
Brainstorming 头脑风暴	11.2%
Chat 聊天	8.4%
Rewrite 改写	6.6%
Summarization 总结	4.2%
Classification 分类	3.5%
Closed QA 封闭问答	2.6%
Extract 抽取	1.9%

这个数据分布很重要，因为它说明真实用户并不是主要在做传统 NLP benchmark 里的分类、阅读理解、翻译任务。真实用户更多是在做：

1. 写作；
2. 改写；
3. 头脑风暴；
4. 问答；
5. 总结；
6. 对话。

这也是为什么论文说：**公开 NLP 数据集不能很好代表真实语言模型使用场景。**

数据规模方面，论文附录 Table 6 给出了具体数量：

数据集	训练来源	数量
SFT train	labeler	11,295
SFT train	customer	1,430
RM train	labeler	6,623
RM train	customer	26,584
PPO train	customer	31,144

也就是说，SFT 阶段更多依赖标注员写的示范；RM 和 PPO 阶段则更多使用真实 API 用户 prompt。

通俗理解：

第一阶段靠“老师写范文”；

第二、三阶段更多靠真实用户问题，让模型学习真实使用环境下什么回答更好。

6. 论文的核心实验结果

6.1 人类更喜欢 InstructGPT

这是论文最重要的结论。

论文发现，在 API prompt 分布上，人类标注员显著更喜欢 InstructGPT 的输出，而不是 GPT-3 的输出。尤其经典的是：

1.3B InstructGPT 的输出，比 175B GPT-3 更受偏好。

此外，175B InstructGPT 相比 175B GPT-3，被偏好的比例达到 85% 左右；相比 few-shot prompted GPT-3，也有 71% 左右的偏好优势。

通俗理解：

与其让一个很大的模型自己猜用户想要什么，
不如让一个模型明确接受“如何当助手”的训练。

6.2 InstructGPT 更会遵循指令

论文 Figure 4 显示，InstructGPT 相比 GPT-3：

1. 更能尝试正确任务；
2. 更能遵守显式约束；
3. 更适合作为 customer assistant；
4. 在封闭域任务中更少幻觉。

所谓“显式约束”，比如：

“请用三句话回答。”
“请用表格输出。”
“请不要超过 100 字。”
“请只根据原文总结。”

GPT-3 可能会忽略这些约束；InstructGPT 更容易按要求来。

通俗理解：

GPT-3 更像“我大概知道你在说什么，然后继续写”。
InstructGPT 更像“我知道你给了一个任务，我要按任务要求交付”。

6.3 InstructGPT 更真实，幻觉更少

论文在 TruthfulQA 上发现，InstructGPT 的真实且有信息量的回答比例明显高于 GPT-3。

另外，在封闭域任务中，比如：

1. 总结；
2. 根据给定文本回答；
3. 不应该引入外部信息的任务；

InstructGPT 的幻觉率约为 21%，GPT-3 约为 41%。

通俗理解：

当任务要求“只根据材料回答”时，InstructGPT 更不容易乱补内容。

不过注意：**更少幻觉不等于没有幻觉。**

论文也明确说，InstructGPT 仍然会犯简单错误。

6.4 毒性有所降低，但偏见没有明显改善

论文发现，在加上 respectful prompt，也就是要求模型输出安全、尊重的内容时，InstructGPT 的毒性输出比 GPT-3 少。根据论文描述，InstructGPT 在这种设置下大约生成少 25% 的毒性输出。

但这个改善有条件：

1. 如果没有 respectful prompt，优势不明显；
2. 如果明确要求模型输出 toxic 内容，InstructGPT 甚至可能输出更 toxic 的内容；
3. 在偏见测试上，比如 Winogender 和 CrowS-Pairs，InstructGPT 没有显著优于 GPT-3。

通俗理解：

RLHF 能让模型更会“在被要求安全时表现安全”，但它没有从根本上解决偏见问题。安全性不是一个简单靠“人类喜欢”就能完全解决的问题。

6.5 InstructGPT 能泛化到一些没怎么训练过的任务

论文还发现，InstructGPT 对一些训练分布外的任务有一定泛化能力，比如：

1. 非英语指令；
2. 代码问答；
3. 代码总结。

论文 Figure 8 展示了相关例子：InstructGPT 能更可靠地按照法语指令写故事，也能回答代码相关问题；而 GPT-3 往往需要更精心的 prompt 才能做到。

这说明模型可能不只是死记硬背某些任务，而是学到了一种更抽象的能力：

“看到用户指令，就尝试按指令完成任务。”

通俗理解：

它不是只学会了 1000 个具体任务，
而是学到了一点“什么叫听指令”。

这对后来的通用 AI assistant 很关键。

7. 这篇论文为什么重要？

我觉得它的重要性主要有五点。

7.1 它把大模型从“续写机器”推向了“指令助手”

GPT-3 的原始形态更像一个文本续写器。

你给它一句话，它根据互联网语料风格继续写。

但 InstructGPT 之后，模型开始更像一个 assistant：

1. 能理解任务；
2. 能遵守格式；
3. 能回答问题；
4. 能根据用户目标组织输出；
5. 能避免一部分明显有害内容。

这就是从 **language model** 到 **assistant model** 的关键转变。

7.2 它证明了“后训练”非常重要

以前很多人关注的是：

模型参数多大？
预训练数据多少？
算力多少？

这篇论文说明：

预训练之后的 fine-tuning / alignment，也可以极大改变模型行为。

甚至在用户体验上，后训练可能比单纯扩大模型更有效。

这也是为什么后来大模型训练通常被分成：

1. **Pretraining**，预训练
2. **Supervised Fine-Tuning**，监督微调
3. **Preference Optimization / RLHF / DPO** 等偏好优化
4. **Safety tuning**，安全对齐

这篇论文基本奠定了这种路线。

7.3 它让“人类偏好”成为训练信号

传统监督学习需要明确标准答案。

但很多开放式任务没有唯一标准答案，比如：

1. 写一封邮件；
2. 总结一篇文章；
3. 解释一个概念；
4. 生成方案；
5. 给建议；
6. 头脑风暴。

这种任务很难说只有一个正确答案，但人类可以比较：

| A 和 B 哪个更好？

RLHF 的关键价值就在这里：

| 它把“人类觉得哪个更好”转化成了模型可以优化的奖励信号。

通俗说：

| 不需要告诉模型唯一标准答案，
只需要告诉它：这几个答案里，人更喜欢哪个。

这非常适合开放式生成任务。

7.4 它解释了为什么公开 NLP benchmark 不够用

论文指出，公开 NLP 数据集往往偏向容易自动评分的任务，比如分类、阅读理解、翻译等。

但真实 API 使用里，生成、头脑风暴、开放问答占比很高。论文中 generation 和 brainstorming 合计已经超过一半。

所以，模型在 benchmark 上表现好，不代表它在真实用户任务中好用。

通俗理解：

传统 benchmark 像考试题。

真实用户任务像工作场景。

考试厉害的人，不一定真的会干活。

InstructGPT 的意义在于，它把评价中心从“考试分数”转向了“真实用户是否觉得有用”。

7.5 它开启了 ChatGPT 类产品的技术路线

这篇论文可以说是 ChatGPT 的直接前身之一。

ChatGPT 背后的核心思想也是：

1. 预训练得到基础模型；
2. 用人类示范教它如何回答；
3. 用人类偏好训练奖励模型或偏好模型；
4. 进一步优化模型行为；
5. 让它更像一个对话助手。

所以你可以把这篇论文理解为：

从 GPT-3 到 ChatGPT 的关键中间环节。

8. 论文里的几个关键概念，用大白话解释

8.1 Alignment，对齐

技术含义：

让模型行为符合人类意图。

大白话：

不是让模型“最会接话”，而是让它“真的帮你做事”。

8.2 Human Feedback，人类反馈

技术含义：

人类对模型输出进行示范、排序、评分或偏好选择。

大白话：

人告诉模型：“这个回答更好，那个回答不行。”

8.3 SFT，监督微调

技术含义：

用人工写好的 prompt-answer 数据训练模型。

大白话：

老师写标准答案，学生照着学。

8.4 Reward Model，奖励模型

技术含义：

训练一个模型预测人类更喜欢哪个输出。

大白话：

训练一个“自动评分老师”。

8.5 PPO，强化学习优化

技术含义：

让语言模型根据奖励模型的分数不断调整输出策略。

大白话：

学生反复写答案，自动评分老师打分，学生逐渐学会怎么拿高分。

8.6 KL Penalty

技术含义：

限制 PPO 后的模型不要偏离原来的 SFT 模型太远。

大白话：

允许学生改进，但不允许为了讨好评分系统而走偏。

8.7 Alignment Tax，对齐税

技术含义：

模型经过对齐训练后，在某些原有能力或 benchmark 上性能下降。

大白话：

把模型训练得更像助手后，它可能在某些考试题上退步。

8.8 PPO-ptx

技术含义：

PPO 训练时混入预训练目标，以保留原始语言能力。

大白话：

一边学怎么服务用户，一边复习原来的基础知识，避免训偏。

9. 这篇论文的局限性

论文自己也承认，InstructGPT 不是完美解决方案。

9.1 它仍然会犯简单错误

论文 Figure 9 举了两个例子：

1. 用户问：“为什么冥想后吃袜子很重要？”

这个问题本身有错误前提。InstructGPT 有时会顺着错误前提解释，而不是指出“吃袜子并不重要”。

2. 用户问：“高速发射炮弹打南瓜会怎样？”

InstructGPT 可能过度谨慎，说有很多可能结果，而不是直接说南瓜大概率会被打碎或炸裂。

通俗理解：

RLHF 让模型更像助手，但也可能让它变得过于迎合、过于谨慎。

9.2 它对齐的是标注员偏好，不是全人类价值

论文明确说，它们对齐的是一组具体标注员和研究人员的偏好，而不是某种普遍的人类价值。

这很重要。

因为不同用户、不同文化、不同场景，对“好回答”的标准可能不同。

例如：

1. 有的人喜欢简洁；
2. 有的人喜欢详细；
3. 有的人希望模型更直接；
4. 有的人希望模型更谨慎；
5. 有的人关心安全；
6. 有的人关心效率。

所以 RLHF 的本质不是“找到绝对正确的价值观”，而是：

| 把某一批人类反馈转化为模型行为偏好。

9.3 奖励模型可能被过度优化

奖励模型只是人类偏好的近似，不是真正的人类本身。

如果模型过度优化奖励模型，可能出现：

1. 表面很好听；
2. 实际不准确；
3. 过度迎合；
4. 话术化；
5. 回答变长但信息密度不高；
6. 为了安全而过度拒答或过度模糊。

这就是后来很多对齐研究继续关注的问题：

| 如何避免模型学会“讨好评分器”，而不是真正帮助用户？

9.4 安全和偏见问题没有根本解决

论文发现 InstructGPT 在毒性方面有一定改善，但偏见方面没有显著改善。

这说明：

RLHF 可以改善模型表层行为，但不一定能彻底消除深层偏见。

模型的偏见可能来自：

1. 预训练数据；
2. 社会语料本身；
3. 标注员偏好；
4. 评价指标设计；
5. 安全指令的副作用。

所以安全对齐需要更复杂的方法，而不只是“让人类选更好的回答”。

10. 用一个完整类比理解 RLHF

可以把整个过程理解成培养一个实习生。

阶段一：预训练 GPT-3

这个实习生读了海量互联网资料。

他知识很多，语言能力很强，但没有经过工作训练。

他可能：

1. 很会写；
 2. 很会接话；
 3. 什么风格都能模仿；
 4. 但不一定知道老板到底要什么。
-

阶段二：SFT

你给他很多优秀工作样例：

用户这样问，你应该这样答。
这类任务要总结。

那类任务要列步骤。
遇到问题要解释原因。
用户要求表格，就要输出表格。

他开始像一个助理。

阶段三：Reward Model

你不再每次亲自写标准答案，而是让他交几版方案。

然后你说：

A 比 B 好。
C 太啰嗦。
D 没有回答问题。
B 更符合用户要求。

于是系统训练出一个“评价主管”，能判断什么答案更可能让你满意。

阶段四：PPO

实习生不断写答案，评价主管不断打分。

慢慢地，实习生学会：

1. 更直接回答问题；
2. 更遵守格式；
3. 更少胡编；
4. 更像一个助手；
5. 更符合人类偏好。

但如果训练过头，他也可能变得：

1. 太圆滑；
2. 太谨慎；
3. 太模板化；
4. 过度迎合评分标准。

所以要用 KL penalty 和 PPO-ptx 控制训练方向。

11. 这篇论文对你理解大模型训练的意义

你可以把大模型训练理解成四层：

第一层：预训练

让模型获得语言能力、知识和通用模式识别能力。

第二层：监督微调 SFT

让模型知道“作为助手应该怎么回答”。

第三层：偏好建模 RM

让模型知道“什么回答更受人类喜欢”。

第四层：偏好优化 PPO / RLHF

让模型主动朝人类偏好的方向调整行为。

这篇论文最重要的贡献，是把第三层和第四层系统化了。

它说明：

大模型的产品体验，不只来自底座能力，
很大程度来自后训练和人类反馈。

这也是为什么同样级别的基础模型，经过不同后训练之后，会呈现出完全不同的性格、格式能力、安全边界和用户体验。

12. 最值得记住的几个结论

1. 预训练目标和用户目标不一致。

预测下一个 token，不等于帮助用户完成任务。

2. RLHF 能显著改善模型的指令遵循能力。

人类更偏好 InstructGPT，而不是原始 GPT-3。

3. 小的对齐模型可以胜过大未对齐模型。

1.3B InstructGPT 可以比 175B GPT-3 更受欢迎。

4. 真实用户任务和公开 NLP benchmark 不一样。

用户大量使用生成、改写、头脑风暴、开放问答，而不是只做分类和阅读理解。

5. RLHF 改善了有用性和部分真实性、安全性，但没有彻底解决幻觉、偏见和安全问题。

6. RLHF 对齐的是特定人群偏好，不是抽象的全人类价值。

7. 对齐也有代价。

如果处理不好，模型在一些传统任务上会退步，这就是 alignment tax。

13. 最后用一句更通俗的话概括

这篇论文真正证明的是：

大模型不是训练完预训练就结束了。
预训练只是让模型“会说话、懂很多”；
RLHF 才开始让模型“像一个人类愿意使用的助手”。