

一句话区分：

- **SFT**：教模型“好答案长什么样”。
- **Reward Model**：教一个模型“哪个答案更好”。
- **RLHF**：让语言模型去追求 Reward Model 认为更好的答案。
- **DPO**：不用单独训练 reward model 再 PPO，直接用 chosen/rejected 偏好对更新语言模型。
- **RLAIF / Constitutional AI**：把一部分“人来判断”换成“AI 按 constitution 判断”。

阶段	输入数据	训练目标	解决问题	局限
Pretraining	大规模无标注文本 token 序列； decoder-only 常用 next-token prediction	最大化训练文本似然：预测下一个 token	学到语言模式、世界知识、基础推理和生成能力	目标只是“续写文本”，不等于“按用户意图安全回答”；可能学到有害、虚假、矛盾的行为
SFT	人类写的 prompt-response 示范数据；instruction 数据	监督微调，让模型模仿高质量回答	把 base model 拉到“会听指令、会按格式回答”的分布上	依赖高质量示范；只能模仿示范，不能很好表达“两个回答哪个更好”的偏好
Reward Model	同一 prompt 下多个模型回答的人类排序 / 偏好比较	训练一个打分模型，预测人类更喜欢哪个回答	把人类偏好转成可优化的标量 reward	reward 是代理目标，可能偏离真实价值；会带入标注者偏好；模型容易 reward hacking
RLHF	SFT 模型、prompt 数据、Reward Model 给出的 reward；常用 PPO + KL 约束	在不偏离 SFT 模型太远的前提下，最大化 RM reward	让模型输出更符合人类偏好，通常更 helpful / harmless / follows instruction	训练复杂、不稳定、算力贵；可能过度优化 RM；对某些原始能力有回退；对齐的是特定标注者偏好，不是普遍人类价值
DPO	偏好数据对：prompt、chosen response、rejected response；通常还需	直接优化策略：提高 chosen 概率，降低 rejected 概	跳过显式 Reward Model 和 PPO，用分类式 loss 直接做	仍依赖偏好数据质量；不天然解决偏好覆盖不足、偏见、安全边界问题；离线

阶段	输入数据	训练目标	解决问题	局限
	要 SFT/reference model	率；隐式包含 reward 和 KL 约束	preference optimization	偏好数据限制了探索能力
Constitutional AI / RLAIIF	一组 constitution 原则、red-team prompts、模型自我 critique/revision、AI 生成的偏好标签	用规则指导模型自我修正，并用 AI feedback 训练 preference model / policy	减少对人工安全标注的依赖；把“安全原则”写成显式规则；提升 harmlessness	constitution 的质量决定上限；AI feedback 可能继承模型自身盲点；规则冲突、过度拒答和价值选择仍需人工把关
Safety Alignment	安全示范、拒答数据、红队数据、有害/无害偏好、安全规则、评测集	降低有害建议、越狱、歧视、幻觉等风险，同时保持有用性	让模型不只是“更会回答”，还要“在危险场景下知道边界”	安全和有用性存在张力；无法穷尽所有风险；过强会变成回避，过弱会放出危险能力