

大模型应用不能只靠“感觉回答得还行”来判断质量。因为 LLM 的输出具有不确定性：

同一个问题可能多次回答不同；

一次 Prompt 优化可能提升某类问题，却损害另一类问题；

模型升级、知识库更新、工具接口变化，也都可能引入新的失败。

因此，eval 的核心价值是把主观体验转化为可重复、可比较、可归因的质量管理机制。OpenAI 也强调，eval 用来测试模型输出是否满足指定的风格与内容标准，尤其适合模型切换、Prompt 修改和应用迭代时做回归测试。

首先要区分 **Model eval** 和 **Product eval**。Model eval 关注模型本身能力，例如推理、指令遵循、事实性、代码能力；Product eval 关注一个完整应用是否完成用户任务，包括检索、工具调用、交互体验、权限、安全、延迟和业务结果。比如一个 RAG 应用回答错了，未必是模型差，可能是召回文档错、chunk 排序差、Prompt 没约束引用，或者知识库本身过期。Product eval 的对象是“系统链路”，不是单个模型。

对 RAG 来说，最核心的是四类指标。

第一，**Context Precision**，看检索出来的内容是否相关，尤其相关 chunk 是否排在前面；

RAGAS 官方定义中，它评估检索器把相关内容排在无关内容之前的能力。

第二，**Context Recall**，看回答所需的信息是否被召回，防止“该找的没找出来”。

第三，**Faithfulness**，看回答中的事实是否都能被检索上下文支持，RAGAS 将其定义为回答与 retrieved context 的事实一致性。

第四，**Answer / Response Relevancy**，看回答是否真正回应了用户问题，而不是虽然正确但跑题。简单说，Precision/Recall 评估“找得好不好”，Faithfulness/Relevancy 评估“答得好不好”。

Agent 的 eval 更复杂，因为 Agent 不只是生成文本，还会多轮规划、调用工具、读写状态、根据反馈调整行动。Anthropic 指出，Agent 会跨多轮使用工具并修改环境状态，错误可能传播和放大。因此 Agent 至少要看五类指标：

一是**任务成功率**，最终是否完成目标；

二是**工具调用准确率**，是否选对工具、参数是否正确；

三是**轨迹质量**，推理路径是否高效、是否绕路或重复；

四是**约束遵循**，是否遵守权限、预算、合规和业务规则；

五是**鲁棒性与恢复能力**，遇到工具失败、信息不足、冲突数据时能否降级、追问或保守输出。

LangChain 的 Agent Evaluation Readiness Checklist 也强调从错误分析、数据集构建、打分器设计，到离线/在线 eval 和生产监控的完整流程。

人工评估和 LLM-as-judge 各有优劣。

人工评估更可靠，尤其适合金融、法律、医疗等高风险场景，可以判断细微语义、业务合理性和合规风险；缺点是成本高、速度慢、难以高频回归。

LLM-as-judge 便宜、快、可规模化，适合做初筛、持续监控和版本对比；缺点是可能不稳定、有偏差、容易被表述方式影响。

因此更合理的做法是：关键样本用专家标注建立“金标准”，大规模样本用自动打分器跑回归，疑难和低置信度样本再回到人工复核。OpenAI 文档也提到，人工 annotation 最有效，而 grader 可以帮助规模化运行评估。

测试集构建要覆盖真实使用，而不是只放“干净样例”。至少包括：高频典型问题、边界问题、历史失败案例、对抗样本、长上下文样本、权限/合规敏感样本、工具异常样本。OpenAI 的最佳实践也建议 eval 数据要包含 typical cases、edge cases 和 adversarial cases，并使用人工专家标注。测试集最好持续沉淀：每次线上失败都进入 error bank，经过清洗和标注后加入回归集。

错误分类是 eval 真正产生价值的地方。不要只记录“答错了”，而要拆成：

- 检索失败
- 排序失败
- 上下文不足
- 模型幻觉
- 引用错误
- 问题理解错误
- 工具调用错误
- 权限/合规错误
- 输出格式错误
- 延迟或成本不可接受

只有分类清楚，才能知道该改 embedding、chunk、rerank、Prompt、工具 schema，还是业务规则。

金融场景尤其需要 eval，因为金融回答往往涉及事实准确性、时效性、合规边界和责任归属。一个错误的收益率、过期的监管口径、未经支持的投资判断，都可能造成业务风险。对金融 AI 应用而言，eval 不是锦上添花，而是从 Demo 走向生产的准入机制：它决定系统能否被审计、能否稳定迭代、能否在高风险场景中被信任。