

同一模型在不同 prompt/context 下表现差异的核心原因在于：

1. **任务描述的清晰度**：prompt 是模型理解任务的指南，模糊会导致随机性；
2. **上下文组织的结构化**：信息分层决定模型关注点；
3. **成功标准与评估机制**：明确标准可提高输出一致性；
4. **输出格式的约束**：structured outputs 限制模型生成的形式；
5. **注意力分配与信息量**：复杂或混乱 prompt 会分散注意力；
6. **模型先验激活**：prompt 微调可触发不同内部模式。

1. Prompt 是模型的“任务说明书”

大语言模型（LLM）并非固定规则引擎，它的输出依赖于上下文理解和模式匹配。每次调用时，模型会将 prompt 作为任务描述、环境设定和期望输出的综合信号。prompt 的清晰度和结构直接影响模型对任务的内部表示。如果 prompt 模糊、信息过多或过少，模型可能无法正确判断任务目标，导致输出差异大。

举例来说，如果你给模型的指令是“生成报告”，没有任何结构说明或背景信息，模型可能随意选择风格、长度和内容重点。而如果指令明确：“请生成一份 500 字、面向高管、强调 KPI 分析报告”，模型的输出会更稳定、更贴近预期。

2. Context 的组织决定信息权重

Anthropic 在《Effective Context Engineering》中强调，将背景、指令、工具说明和输出格式分层组织，可以让模型理解哪些信息是核心，哪些是参考。不同的 context 设计意味着模型在内部注意力分配上不同：

- **背景信息**（如公司、行业数据）帮助模型建立知识框架；
- **操作指令**（任务目标、约束条件）明确执行路径；
- **工具说明**（可调用函数、数据源）让模型知道如何操作外部资源；
- **输出格式约束**（JSON schema、表格结构）限制生成形式。

如果 context 缺失层次或混乱，模型可能过度关注无关信息，或忽略关键指令，造成输出偏差。

3. 成功标准与评估反馈的重要性

Claude Prompt Engineering 强调“先定义成功标准，再建立评估机制”，与金融 KPI 设计类似。不同的 prompt 会隐含不同的成功标准，即模型不知道什么算好结果时，输出易出现偏差。例

如：

- Prompt A 没有明确评价标准 → 模型可能生成风格多样、重点不明确的文本；
- Prompt B 明确 KPI/评分规则 → 模型会优化输出以满足这些规则，结果更一致。

因此，prompt 的差异直接影响模型“理解任务成功”的方式。

4. Structured Outputs 与 Function Calling 的边界

OpenAI 的 structured outputs 文档指出，模型在明确的结构化输出要求下，会生成符合 JSON schema 或表格的内容，但在边界不清或 schema 模糊时，模型容易生成错误或不一致的格式。例如：

- 指令明确要求输出 `{name, age, salary}` → 模型严格遵循；
- 指令只要求“列出员工信息” → 模型可能附加无关字段或省略字段。

这说明，prompt 与 context 的精确度越高，模型输出的一致性越强。

5. 信息量与注意力分布

模型的注意力机制会分配计算资源关注不同 token。当 prompt 太长、信息复杂或逻辑混乱时，注意力可能分散，导致模型对核心任务理解不足，从而表现差异大。相反，精简、层次清晰的 prompt 可以让模型聚焦重要信息，生成更可靠的结果。

6. 模型内部偏差与默认假设

每个 LLM 都有训练语料中形成的“先验假设”，在缺乏明确指令时，会根据常见模式填充内容。不同 prompt 会激活不同的先验模式：

- “写一篇科技新闻摘要” → 模型倾向科技报道风格；
- “写一篇科技新闻摘要，强调风险与政策影响” → 模型激活分析性、政策导向模式。

即使是同一模型，prompt 的微小变化也可能触发不同的内部模式，导致输出差异大。
