

过去的大模型竞争，核心是**预训练规模竞争**。CS324 的 Scaling Law 材料强调，语言模型性能会随着数据、参数和计算量呈现相对稳定的提升规律。因此早期竞争很直接：谁能拿到更多数据、更多 GPU、更大的模型，谁就更可能得到更强的 base model。GPT-3 这类模型代表了这条路线：通过 next-token prediction 学到语言、知识和一定推理能力。但问题也很明显：预训练目标只是“预测下一个 token”，不等于“理解用户意图”，也不等于“可靠地完成复杂任务”。

中间阶段的突破，是 **SFT / RLHF 带来的助手化**。InstructGPT 材料里有一个关键判断：模型变大，并不会天然变得更会遵循用户意图。SFT 用人类示范教模型“好回答长什么样”；Reward Model 用偏好数据学习“哪个回答更好”；RLHF 再用 PPO 优化模型，让它更 helpful、honest、harmless。这个阶段的意义是把“会续写文本的模型”变成“会对话、会听指令的助手”。但 RLHF 主要解决的是可用性、偏好和安全风格，不一定真正释放深度推理能力。

DeepSeek-R1 重要，是因为它把竞争焦点进一步推向 **RL + Test-Time Compute**。R1 论文最核心的信号是：复杂推理能力可以通过强化学习被激发出来，甚至不一定依赖大量人工标注的推理轨迹。DeepSeek-R1-Zero 直接在 DeepSeek-V3-Base 上做 RL，用可验证任务的正确性作为奖励，让模型自然学出 self-reflection、verification、动态调整策略等行为。也就是说，模型不是被人一步步教“该怎么想”，而是在可验证反馈中学会“为了答对，应该多想、复查、换路线”。

这和 test-time compute 材料中的“慢思考”逻辑是一致的：推理模型的能力不只来自训练时参数里的知识，也来自推理时愿意花更多 token、更多步骤、更多验证。过去应用模型追求低延迟、快速回答；现在复杂任务开始接受“慢一点但更可靠”。推理能力变成一种可以在推理阶段扩展的资源：多想几步、多采样、多验证，就可能换来更高正确率。

产业意义很大。第一，DeepSeek-R1 说明顶级推理能力不只靠无限堆预训练规模，也可以通过高质量 RL 环境、可验证奖励和工程优化获得。第二，它降低了人工推理标注的重要性：如果任务有明确答案，例如数学、代码、部分金融计算，就可以用规则奖励训练。第三，R1 展示了蒸馏价值：大模型中涌现的推理模式，可以迁移到更小模型，让小模型也获得较强推理能力。这会改变成本结构：不是所有场景都必须调用最大模型。

对 AI 应用来说，未来更合理的架构不是“一个模型打天下”，而是**任务分流**。普通问答、摘要、分类、格式转换，用低成本模型；复杂规划、数学推导、代码生成、投研归因、风险分析，用推理模型；关键结论再交给 verifier、工具或规则系统复核。模型选择会从“谁参数最大”转向“这个任务需不需要慢思考”。

对金融 Agent 项目，启发尤其直接。金融任务天然包含大量可验证环节：财务指标计算、估值假设、同比环比、组合风险、事件归因、研报一致性检查。这些任务适合引入“推理模型 + 工具 + 验证器”的结构。简单信息抽取用便宜模型；涉及投资判断、因果链、异常解释时切到 R1 类推理模型；最终输出必须带来源、计算过程、置信度和风险提示。

DeepSeek-R1 的重要性不只是“又一个强模型”，而是它证明了大模型竞争正在从**预训练规模竞赛**，转向**推理训练、推理时计算、可验证反馈和蒸馏生态**的综合竞争。对于金融 Agent，这意味

着真正的护城河不只是接入哪个模型，而是如何设计任务路由、验证闭环和成本可控的推理 workflow。