

Agent 从 Demo 走向生产，核心问题不是“会不会调用工具”，而是能不能在不确定环境里稳定、可控、可追责地完成任务。一个生产级 Agent，本质上应被看作“LLM + 工具 + 状态机 + 权限系统 + 观测系统”的组合，而不是一个更聪明的聊天机器人。OpenAI Agents SDK 也把 Agent 定义为配置了 instructions、tools，以及 guardrails、handoffs、structured outputs 等运行行为的 LLM 应用单元。

一、Agent 如何避免无限循环？

无限循环通常来自三类原因：目标不清、工具结果无法推进、模型反复重试。生产系统不能只靠 prompt 说“不要循环”，而要设置硬约束：最大推理轮次、最大工具调用次数、单工具超时、总 token 预算、相同 tool call 去重、状态无进展检测。更重要的是，每一轮都要判断“任务状态是否发生变化”。如果连续两轮没有新增事实、没有新文件、没有新结果，就应触发停止或 fallback。Agent loop 应该像工作流一样有退出条件，而不是开放式聊天。

二、如何做 tool schema 校验？

Tool schema 是 Agent 和外部世界之间的契约。每个工具都应有明确的 JSON Schema / Pydantic 模型，定义字段名、类型、必填项、枚举值、默认值和边界条件。模型生成 tool arguments 后，必须先经过 schema validation，再进入真实工具执行。校验失败时，不应直接执行，而是返回结构化错误，让 Agent 修正一次；多次失败则降级。LangChain 的 structured output 文档也强调，用 JSON 对象、Pydantic model 或 dataclass 这类结构化形式，可以让应用拿到可预测的数据，而不是事后解析自然语言。

三、如何做权限控制？

权限控制不能交给模型自觉。正确做法是“模型建议，系统裁决”。工具应按风险分级：只读工具、低风险写入工具、高风险外部动作工具。比如搜索、读取文件可以自动执行；发邮件、下单、删除数据、修改生产配置必须要求人工确认。权限还要和用户身份、资源范围、环境隔离绑定，例如某个 Agent 只能访问指定目录、指定数据库表、指定 API scope。模型即使生成了合法 tool call，也只能在授权范围内运行。

四、如何做日志和 trace？

生产 Agent 必须能回答：用户问了什么、模型想了什么、调用了什么工具、工具返回了什么、最终为什么这么答。日志至少包括 request_id、user_id、session_id、model、prompt version、tool name、tool arguments、tool result、latency、token、cost、error type 和 final answer。Trace 则要记录完整链路，尤其是多轮 ReAct、工具调用和中间状态。LangSmith 将其定位为用于构建、调试和部署 LLM 应用的平台，重点能力包括 trace、evaluate、test prompts 和 deployment management。

五、如何区分事实、推断和幻觉？

一个可用的 Agent 输出不应把所有内容都写成确定语气。事实必须来自工具返回、数据库、文件或用户输入；推断是基于事实的解释，需要标明依据；幻觉则是没有来源、却被写成事实的内容。工程上可以要求 Agent 输出结构化字段：facts、evidence、inferences、

uncertainties、unsupported_claims。凡是没有 evidence_id 的结论，默认不能进入正式报告，只能进入“可能解释”或“待验证假设”。

六、如何设计 fallback?

Fallback 是预设的安全兜底方案。常见 fallback 包括：工具超时后改用缓存；搜索不足时只基于已有材料回答；schema 校验失败后请求模型重写参数；多次失败后转人工；高风险动作前暂停确认；模型输出不完整时返回部分结果并说明缺口。好的 fallback 应该保守、透明、可恢复，而不是编造一个看似完整的答案。

七、如何评估 Agent 是否真的完成任务?

Agent 评估不能只看回答流畅度，而要看任务完成度。可以拆成五类指标：结果正确性、步骤合规性、工具使用合理性、成本与时延、用户目标达成。对于固定任务，应建设 golden dataset，比较不同 prompt、模型和工具版本；对于生产流量，应做在线评估和人工抽检。LangSmith 的 evaluation 文档也强调，可用 curated datasets 比较 agent 版本、做 benchmark，并在生产中用 online evals 监控交互质量。

归根结底，Agent 生产化不是让模型“更自由”，而是让模型在边界内自主。**无限循环、schema、权限、trace、事实边界、fallback、评估，分别对应 Agent 的稳定性、契约性、安全性、可观测性、可信度、韧性和可验收性。**只有这些问题被系统化处理，Agent 才能从“会演示”变成“可上线”。